

# Angewandte Mathematik



Dr. rer. nat. Johannes Riesterer

Für fast alle (hinreichend große) **Mathlib**

Für einen Filter  $I$  bedeutet die Bedingung  $\forall^f x \, p(x)$  dass die Menge der Elemente, für die  $p(x)$  gilt, ein Element des Filters  $I$  ist, also  $\{X \mid p(x)\} \in I$ .

### Big O Notation [Mathlib](#)

Für einen Filter  $I$  und Funktionen  $f, g$  definieren wir

$$f = \mathcal{O}[I]g \leftrightarrow \exists c > 0, \forall^f x \in I, \|f(x)\| \leq c \cdot \|g(x)\|$$

### Erklärung

Die Aussage besagt, dass für fast alle  $x$  in der Menge  $I$ , die Norm von  $f(x)$  durch ein Vielfaches der Norm von  $g(x)$  beschränkt ist. Das Vielfache wird durch die Konstante  $c$  dargestellt.

### Klein-o Notation [Mathlib](#)

Für einen Filter  $I$  und Funktionen  $f, g$  definieren wir

$$f = o[I]g \leftrightarrow \forall c > 0, \forall^f x \in I, \|f(x)\| \leq c \cdot \|g(x)\| \text{ für } x \geq N$$

### Erklärung

Die Aussage besagt, dass für jede positive Konstante  $c$  und für fast alle  $x$  in der Menge  $I$  die Norm von  $f(x)$  kleiner oder gleich  $c \cdot \|g(x)\|$  ist. Dies beschreibt, dass  $f(x)$  asymptotisch schneller gegen 0 geht als  $g(x)$ . In anderen Worten, der Ausdruck  $\frac{\|f(x)\|}{\|g(x)\|}$  geht gegen 0 entlang  $I$ , wobei mögliche Probleme durch Division durch Null durch diese Definition vermieden werden.

### Beweis: Klein-o impliziert Groß-O [Mathlib](#)

Wenn  $f = o[I]g$ , dann ist  $f = O[I]g$ .

### Klassische Definition in einer Dimension:

$$f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}$$

### Definition mit $o$ -Kalkül:

$$f(a+h) = f(a) + f'(a)h + o(h)$$

### Äquivalenz:

#### 1. Von $o(h)$ zur klassischen Definition:

$$\frac{f(a+h)-f(a)}{h} = f'(a) + \frac{o(h)}{h}$$

Mit  $\lim_{h \rightarrow 0} \frac{o(h)}{h} = 0$  folgt die klassische Definition.

#### 2. Von der klassischen Definition zur $o(h)$ -Form:


Nehmen wir  $f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h)-f(a)}{h}$ , dann:

$f(a+h) = f(a) + f'(a)h + r(h)$ , wobei  $r(h)$  der Restterm ist.

Da  $\lim_{h \rightarrow 0} \frac{r(h)}{h} = 0$ , gilt  $r(h) = o(h)$ .

# Angewandte Mathematik

## Ableitungen



### Lokale Linearisierung

Eine Funktion  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$  heisst differenzierbar in  $a \in U$  falls es eine lineare Funktion  $df(a) : \mathbb{R}^n \rightarrow \mathbb{R}^m$  gibt mit

$$f(a + h) = f(a) + df(a)h + o(\|h\|) \quad (1)$$

$$\Leftrightarrow \lim_{h \rightarrow 0} \frac{f(a + h) - f(a) - df(a)h}{\|h\|} = 0 \quad (2)$$

für alle  $h \in \mathbb{R}^n$

### Bedeutung

Eine differenzierbare Funktion kann auf hinreichend kleinen Umgebungen beliebig genau durch eine lineare Funktion approximiert werden.

### Beispiel

$$A \in \mathbb{R}^{n \times m}, b \in \mathbb{R}^n$$

$$f(x) := A \cdot x + b \quad (3)$$

$$df(a) := A \quad (4)$$

### Beweis

$$\lim_{h \rightarrow 0} \frac{A(x+h) - A \cdot x - A \cdot h}{||h||} = \quad (5)$$

$$\lim_{h \rightarrow 0} \frac{A \cdot x + A \cdot h - A \cdot x - A \cdot h}{||h||} = 0 \quad (6)$$



### Eindeutigkeit

Die Ableitung  $df$  ist eindeutig bestimmt.

### Beweis

Ist  $df'$  eine weitere Abbildung mit Eigenschaft (1), so gilt für jeden Basisvektor  $e_i$

$$\lim_{t \rightarrow 0} \frac{f(a + te_i) - f(a) - df(a)te_i}{\|te_i\|} = 0 \quad (7)$$

$$\lim_{t \rightarrow 0} \frac{f(a + te_i) - f(a) - df'(a)te_i}{\|te_i\|} = 0 \quad (8)$$

$$\Rightarrow (df(a) - df'(a))(e_i) = \lim_{t \rightarrow 0} \frac{(df'(a) - df(a))(te_i)}{\|te_i\|} = 0 \quad (9)$$

## Definition

Eine Abbildung  $T : V \rightarrow W$  zwischen zwei Vektorräumen  $V$  und  $W$  über einem Körper  $K$  heißt **linear**, wenn für alle  $v_1, v_2 \in V$  und alle  $\alpha, \beta \in K$  gilt:

$$T(\alpha v_1 + \beta v_2) = \alpha T(v_1) + \beta T(v_2).$$

## Eigenschaften

- Lineare Abbildungen erhalten die Vektorraumstruktur: Sie respektieren die Addition und die Skalarmultiplikation.
- Jede lineare Abbildung ist durch ihr Verhalten auf einer Basis des Vektorraums eindeutig bestimmt.
- Die Ableitung einer linearen Abbildung ist die Abbildung selbst: Für eine lineare Abbildung  $T$  gilt  $D(T) = T$ .

## Beispiele

- Die Identitätsabbildung  $\text{id}_V : V \rightarrow V$ , definiert durch  $\text{id}_V(v) = v$ , ist linear.
- Projektionen und Rotationen in  $\mathbb{R}^n$  sind lineare Abbildungen.
- Matrizen wirken als lineare Abbildungen auf Vektorräumen.

### Lineare Abbildung in Lean Mathlib

In Lean4 (Mathlib) wird eine lineare Abbildung  $T$  zwischen zwei normierten Vektorräumen  $V$  und  $W$  über  $\mathbb{R}$  als eine stetige lineare Abbildung (`continuous_linear_map`) definiert:

$$T : V \rightarrow L[\mathbb{R}]W$$

Die lineare Struktur wird durch zwei Eigenschaften beschrieben:

- `map_add` :  $T(v_1 + v_2) = Tv_1 + Tv_2$
- `map_smul` :  $T(c \cdot v) = c \cdot Tv$

### Vergleich

Im endlichdimensionalen Fall entspricht die Definition in Lean der üblichen Definition einer linearen Abbildung. Im unendlichdimensionalen Fall wird zusätzlich die Stetigkeit gefordert, da diese nicht automatisch gegeben ist.

### Definition

Eine Funktion  $f$  ist an  $x$  differenzierbar, wenn:

$$f(x') - f(x) - f'(x' - x) = o[L](x' - x)$$

Dies bedeutet, dass der Restterm  $f(x') - f(x) - f'(x' - x)$  schneller gegen 0 geht als  $x' - x$ , wenn  $x' \rightarrow x$  unter einem Filter  $L$ .

### Beispiele für Filter $L$

- **Standardfall: Filter der Umgebung von  $x$**

Der Filter  $L = \mathcal{N}(x)$  beschreibt, dass  $x'$  beliebig nahe an  $x$  heranrückt. Dieser Filter erfasst alle offenen Umgebungen von  $x$ .

$$o[\mathcal{N}(x)](x' - x)$$

bedeutet, dass der Restterm verschwindet, wenn  $x'$  gegen  $x$  läuft.

### Beispiele für Filter $L$ (Fortsetzung)

- **Filter auf einem Teilraum:**

Wenn man Differenzierbarkeit nur auf einem Teilraum  $S \subseteq E$  betrachtet, verwendet man den Filter  $\mathcal{N}[S](x)$ , der Umgebungen in  $S$  enthält. Damit kann man die Differenzierbarkeit von  $f$  auf  $S$  testen.

- **Filter für gerichtete Mengen:**

Bei Funktionen auf gerichteten Mengen (z.B. in Optimierungsproblemen) verwendet man den Filter  $L$ , der beschreibt, wie  $x'$  sich entlang einer Richtung oder eines Pfades  $\gamma(t) \rightarrow x$  nähert.

### Zusammenfassung

Der Filter  $L$  gibt die Art und Weise an, wie  $x'$  gegen  $x$  strebt. Der häufigste Fall ist der Filter der offenen Umgebungen von  $x$ , aber auch Teilräume oder spezielle Pfade können durch Filter modelliert werden.

## Kettenregel für differenzierbare Funktionen

Gegeben seien differenzierbare Funktionen  $f : E \rightarrow F$  und  $g : F \rightarrow G$  mit

$$f'(x) : E \rightarrow F \quad \text{und} \quad g'(f(x)) : F \rightarrow G,$$

wobei  $f'(x)$  und  $g'(f(x))$  die Ableitungen von  $f$  bzw.  $g$  an den jeweiligen Punkten darstellen.

Dann ist die Komposition  $h = g \circ f$  differenzierbar und die Ableitung  $h'(x)$  gegeben durch:

$$h'(x) = g'(f(x)) \circ f'(x).$$

## 1. Definition des Fehlerterms für $f$

Da  $f$  an  $x$  differenzierbar ist:

$$f(y) = f(x) + f'(x)(y - x) + o(\|y - x\|),$$

wobei der Fehlerterm  $o(\|y - x\|)$  schneller gegen Null geht als  $\|y - x\|$ .

## 2. Definition des Fehlerterms für $g$

Da  $g$  an  $f(x)$  differenzierbar ist:

$$g(f(y)) = g(f(x)) + g'(f(x))(f(y) - f(x)) + o(\|f(y) - f(x)\|).$$



## 3. Einsetzen des Fehlers von $f$ in den Fehler von $g$

Ersetzen von  $f(y) - f(x)$  durch den Ausdruck aus Schritt 1 ergibt:

$$g(f(y)) = g(f(x)) + g'(f(x)) (f'(x)(y - x) + o(\|y - x\|)) \\ + o(\|f(y) - f(x)\|).$$

## 4. Vereinfachen und Abschätzen

Da die Terme  $g'(f(x))(o(\|y - x\|))$  und  $o(\|f(y) - f(x)\|)$  gegen Null gehen, ist

$$h(y) = h(x) + h'(x)(y - x) + \text{Fehlerterm},$$

was die Differenzierbarkeit von  $h = g \circ f$  zeigt.

## Schritt-für-Schritt-Übersetzung **Mathlib**

- `hg : HasFDerivAtFilter g g' (f x) L'` und `hf : HasFDerivAtFilter f f' x L` entsprechen den Differenzierbarkeitsannahmen von  $g$  und  $f$ .
- `eq1` und `eq2` repräsentieren die asymptotischen Abschätzungen, die den klassischen Fehlertermen entsprechen.
- `refine .of_isLittle0 <| eq2.triangle <| eq1.congr_left` verwendet die Dreiecksungleichung und die  $o(\cdot)$ -Schranksen, um die Differenzierbarkeit zu folgern.




Figure: Quelle: Wikipedia

Automatisches Ableiten in Pytorch

Automatisches Ableiten in JAX

### Ableitung Berechnen

Wie kann man die Ableitung einer Funktion berechnen?

### Partielle Ableitung

Für eine Funktion  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  definiert man die partielle Ableitung

$$D_i f(x) = \lim_{t \rightarrow 0} \frac{f(x + t \cdot e_i) - f(x)}{t}$$

wobei  $e_i$  der  $i$ -te Einheitsvektor ist.

$$\frac{\partial f(x)}{\partial x_i} := D_i f(x).$$


### Richtungsableitung [Mathlib](#)

Allgemeiner definiert man für  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  und  $v \in \mathbb{R}^n$

$$D_v f(x) = \lim_{t \rightarrow 0} \frac{f(x + t \cdot v) - f(x)}{t}$$

die Richtungsableitung (Linienableitung) von  $f$  an der Stelle  $x$  in Richtung  $v$ .

The tangent line in the direction of  $x$ .



### Gradient

Der Vektor

$$\nabla f(a) := \begin{pmatrix} \frac{\partial f(a)}{\partial x_1} \\ \vdots \\ \frac{\partial f(a)}{\partial x_n} \end{pmatrix}$$

wird als Gradient bezeichnet.




Figure: Quelle: Wikipedia:

## Beispiel 1: Quadratische Funktion in 2D

$$f(x, y) = x^2 + y^2$$

Gradient:

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x \\ 2y \end{pmatrix}$$

## Beispiel 2: Quadratische Funktion in 3D

$$f(x, y, z) = x^2 + y^2 + z^2$$

Gradient:

$$\nabla f(x, y, z) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{pmatrix} = \begin{pmatrix} 2x \\ 2y \\ 2z \end{pmatrix}$$



## Beispiel 3: Exponentialfunktion

$$f(x, y) = e^{x^2+y^2}$$

Gradient:

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial}{\partial x} e^{x^2+y^2} \\ \frac{\partial}{\partial y} e^{x^2+y^2} \end{pmatrix} = \begin{pmatrix} 2xe^{x^2+y^2} \\ 2ye^{x^2+y^2} \end{pmatrix}$$

## Beispiel 4: Logarithmische Funktion

$$f(x, y) = \ln(x^2 + y^2)$$

Gradient:

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial}{\partial x} \ln(x^2 + y^2) \\ \frac{\partial}{\partial y} \ln(x^2 + y^2) \end{pmatrix} = \begin{pmatrix} \frac{2x}{x^2+y^2} \\ \frac{2y}{x^2+y^2} \end{pmatrix}$$

# Vergleich: Lineare Abbildungen in Mathematik und Lean (Mathlib)

## Richtungsableitung und Ableitung

$$D_v f(x) = df(x)v$$

und damit insbesondere  $df(a) \cdot h = \langle \nabla f(a), h \rangle$ .

## Beweisg

Folgt aus der Eindeutigkeit der Ableitung.

# Ziel: Linienableitung innerhalb einer Menge zeigen

## Lemma: HasFDerivWithinAt.hasLineDerivWithinAt

Wenn  $f$  an  $x$  innerhalb der Menge  $s$  differenzierbar ist mit Ableitung  $L$ , dann hat  $f$  eine Richtungsableitung (Linienableitung) in Richtung  $v$ , die durch  $L(v)$  gegeben ist:

$$\text{HasFDerivWithinAt } f \ L \ s \ x \Rightarrow \text{HasLineDerivWithinAt } \mathbb{K} \ f \ (L(v)) \ s \ x \ v.$$

## 1. Definition einer Hilfsfunktion $F$

Um die Richtungsableitung in Richtung  $v$  zu bestimmen, definieren wir die Funktion

$$F(t) := x + t \cdot v.$$

Damit repräsentiert  $F$  eine Bewegung entlang der Richtung  $v$  vom Punkt  $x$  aus.

## 2. Darstellung von $x$ durch $F$

Wir erkennen, dass  $x = F(0)$ , also der Punkt  $x$  durch die Funktion  $F$  bei  $t = 0$  beschrieben werden kann. Dies verwenden wir, um  $x$  im Beweis durch  $F(0)$  zu ersetzen:

rewrite:  $x = F(0)$  in hf.

# Beweisschritte: Berechnung der Ableitung von $F$

## 3. Ableitung von $F$ innerhalb der Menge $s$

Da  $F(t) = x + t \cdot v$ , können wir die Ableitung von  $F$  an  $t = 0$  innerhalb der Menge  $F^{-1}(s)$  berechnen. Diese Ableitung ist:

$$\text{HasDerivWithinAt } F (0 + 1 \cdot v) (F^{-1}(s)) 0.$$

Diese Ableitung resultiert aus der Kombination der konstanten Funktion  $x$  und der Identitätsfunktion, multipliziert mit  $v$ .

## 4. Vereinfachung der Ableitung

Die Berechnung vereinfacht sich zu:

$$\text{HasDerivWithinAt } F v (F^{-1}(s)) 0.$$

durch die Gleichungen  $1 \cdot v = v$  und  $0 + v = v$ .

## 5. Kombination der Ableitungen

Mit der Kettenregel schließen wir, dass die Richtungsableitung von  $f$  in Richtung  $v$  durch  $L(v)$  gegeben ist:

$$\text{HasLineDerivWithinAt } \mathbb{K} f (L(v)) s \times v.$$

Dies zeigt, dass die Ableitung von  $f$  in Richtung  $v$  der Anwendung von  $L$  auf  $v$  entspricht.

### Gradient

Sei  $f : U \rightarrow \mathbb{R}$  differenzierbare Funktion,  $a \in U$  und  $v := \operatorname{argmax}_{\|h\|=1} \{\partial_h f(a)\}$ . Dann gilt

$$\|\nabla f(a)\|_v = \nabla f(a) .$$

### Gradient

Der Gradient zeigt in die Richtung des steilsten Anstiegs.

### Beweis

Für beliebiges  $h$  gilt

$$\partial_h f(a) = df(a)h = \langle \nabla f(a), h \rangle = \|\nabla f(a)\| \cdot \|h\| \cdot \cos(\varphi)$$

wobei  $\varphi$  den Innenwinkel zwischen  $\nabla f(a)$  und  $h$  bezeichnet. Für  $\|h\| = 1$  wird somit  $\partial_h f(a)$  maximal, wenn  $\varphi = 0$  und somit  $h = \frac{\nabla f(a)}{\|\nabla f(a)\|}$  ist.



### Extrema

Sei  $f : X \subset \mathbb{R}^n \rightarrow \mathbb{R}$  eine reelle Funktion. Ein Punkt  $a \in X$  heißt lokales Maximum bzw. Minimum, falls eine Umgebung  $U$  von  $a$  existiert, so dass  $f(x) \leq f(a)$  bzw.  $f(x) \geq f(a)$  für alle  $x \in U$  gilt. Liegt einer der beiden Fälle vor, so spricht man von einem lokalen Extremum. Gilt strikt  $f(x) < f(a)$  bzw.  $f(x) > f(a)$ , so nennt man das Extremum isoliert. Ist  $U = X$  so nennt man es auch globales Maximum bzw. Minimum.




Figure: Quelle: Wikipedia:  
<https://en.wikipedia.org/wiki/File:MaximumParaboloid.png>




Figure: Quelle: Wikipedia:

<https://en.wikipedia.org/wiki/File:MaximumCounterexample.png>

### Extrema Mathlib

Ist  $f : U \rightarrow \mathbb{R}$  differenzierbar und hat  $f$  in  $a \in U$  ein lokales Extremum, so gilt

$$\frac{\partial}{\partial x_1} f(a) = \dots = \frac{\partial}{\partial x_n} f(a) = 0 .$$

Sind die partiellen Ableitungen stetig, ist dies gleichbedeutend mit  $df(a) = 0$ .

### Kritischer Punkt

Ein Punkt  $a$  mit  $df(a) = 0$  wird kritischer Punkt genannt.

### Beweis

Setze  $F_k(t) := f(a + te_k)$ . Da  $f$  ein Extremum in  $a$  hat, hat  $F_k$  in einer hinreichend kleinen Umgebung um 0 ein Extremum. Da  $F_k$  eine Funktion einer Veränderlichen ist, gilt  $F'_k(0) = 0$ . Da  $\frac{\partial}{\partial x_k} f(a) = F'_k(0)$  folgt die Behauptung.