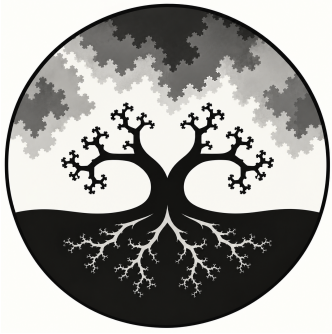


Angewandte Mathematik

Vorlesung 5 von 10

Ableitung

Skript: Abschnitt 4.4

Ablauf heute

0:00	Rückblick: Räume und Konvergenz	Vorlesung 4
0:10	Teil 1: Landau-Symbole – o längs eines Filters	Skript 4.4
0:35	Ableitung in einer Variablen: die beste Gerade, Fermat	Skript 4.4
0:55	*Pause*	
1:10	Teil 2: Mehrere Veränderliche, partielle Ableitungen	Skript 4.4
1:35	Jacobi-Matrix: Beispiele, Kettenregel, Hesse-Matrix	Skript 4.4
1:55	Zusammenfassung und Ausblick	
2:00	Lean live: Blatt 5, Teil B anfangen	Übungsblatt 5
2:30	Ende	

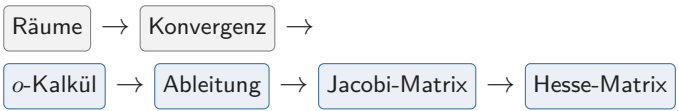
Rückblick: Vorlesung 4

- **Vier Stufen:** topologischer Raum (nahe?), metrischer Raum (wie weit?), normierter Raum (wie lang? $x + y$?), Innenproduktraum (welcher Winkel?). Jede Stufe liefert die darunter mit.
- **Filter:** ein System „großer“ Mengen. Das Ganze ist groß, Obermengen großer Mengen sind groß, zwei große Mengen haben großen Schnitt.
- $\mathcal{N}(a)$ schrumpft auf den Punkt a, atTop auf nichts: der Punkt „$+\infty$“, den es nicht gibt.
- **Schließlich:** $P(x)$ gilt schließlich längs F, wenn $\{x \mid P(x)\}$ groß ist. Mathlib hat dafür einen eigenen Quantor: „für schließlich alle x längs F“.
- **Tendsto:** f strebt längs F gegen G, wenn Urbilder großer Mengen groß sind. *Ein* Begriff für alle Grenzwerte – für Folgen genau die ε-N-Definition.
- **Summenregel:** einmal bewiesen, für jeden Filter – ε halbieren; das Maximum der N steckt im dritten Axiom.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.2: der Quantor, verglichen mit „für alle“

Was worauf aufbaut

Die Begriffe bauen aufeinander auf:



Die Landau-Symbole wären ohne Filter nicht zu erklären, die Ableitung nicht ohne Landau-Symbole. Und jeder Begriff hat ein Minimum an Struktur, mit dem er auskommt:

Thema	**braucht**	**Stufe**
Landau-Symbole	einen Filter + Größen vergleichen	normiert
Ableitung, Jacobi-Matrix	dazu Addition: Näherung = Differenz	normiert
Gradient	ein Skalarprodukt	Innenproduktraum

Vorlesung 5

Landau-Symbole: Vergleichen längs eines Filters

Vernachlässigbar klein

Klassisch heißt $f = o(g)$ für $x \to a$: $\dfrac{f(x)}{g(x)} \to 0$. Das hat zwei Haken:

- **Man teilt.** Wird g nahe a null, ist der Quotient nicht erklärt – und durch einen Vektor kann man gar nicht teilen.
- **Jedes „$x \to \ldots$“ braucht eine eigene Fassung:** gegen einen Punkt, von rechts, gegen ∞, für Folgen.

Mathlib behebt beides auf einmal:

- **Statt zu teilen**, vergleicht man mit einem Faktor: $\|f(x)\| \le c\,\|g(x)\|$.
- **Statt „$x \to a$“** nimmt man einen *Filter* l: ein System „großer“ Mengen mit
  (i) das Ganze ist groß,
  (ii) Obermengen großer Mengen sind groß,
  (iii) der Schnitt zweier großer Mengen ist groß.

  Eine Aussage gilt *schließlich* längs l, wenn die Menge der Punkte, an denen sie gilt, groß ist.

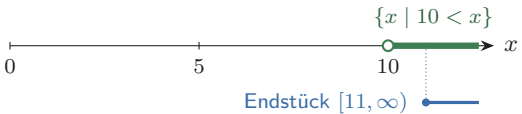
„Schließlich“: die Menge, auf der P gilt

Definition (Schließlich)

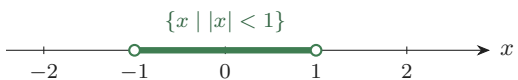
$P(x)$ gilt *schließlich* längs l, wenn die Menge $\{\, x \mid P(x) \,\}$ groß ist, also in l liegt.

Groß heißt bei atTop: enthält ein Endstück; bei $\mathcal{N}(a)$: enthält eine Kugel um a. Beide Mengen im Bild sind groß. Was weit weg vom Ziel geschieht, zählt nicht.

$P(x)$: $10 < x$, längs atTop



$P(x)$: $|x| < 1$, längs $\mathcal{N}(0)$



selbst eine Kugel um 0

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.2: „schließlich“ als Mengenaussage, $\{x \mid 10 < x\}$ im Filter atTop und die Kugel um 0

Klein-o längs eines Filters

Definition (Landau-Symbole längs eines Filters)

Seien f, g Abbildungen von X in normierte Räume und l ein Filter auf X.

$$f = o(g) \text{ längs } l \iff \text{für } \textit{jedes } c > 0 \text{ gilt schließlich } \|f(x)\| \leq c\,\|g(x)\|,$$
$$f = O(g) \text{ längs } l \iff \text{für } \textit{ein } c \text{ gilt schließlich } \|f(x)\| \leq c\,\|g(x)\|.$$

Schließlich heißt: Die Menge $\{\, x : \|f(x)\| \leq c\,\|g(x)\| \,\}$ ist groß.

- O: höchstens so groß wie g, bis auf einen festen Faktor. o: *jeder* noch so kleine Faktor reicht – gegen g ist f vernachlässigbar. So ist $3x = O(x)$, aber nicht $o(x)$.
- **Die Reihenfolge trägt die Bedeutung:** erst c, dann die große Menge. Je kleiner c, desto näher muss man herangehen – zu jedem c eine eigene große Menge.
- Das $=$ ist keine Gleichung: Aus $x^2 = o(x)$ und $x^3 = o(x)$ folgt nicht $x^2 = x^3$. Gemeint ist $f \in o(g)$.

Was „schließlich“ heißt, sagt der Filter

Setzt man die wichtigsten Filter ein, kommen die vertrauten Formen heraus (c statt ε):

Filter	**groß heißt: enthält**	$f = o(g)$ **heißt ausgeschrieben**
$\mathcal{N}(a),\ x \to a$	eine Kugel $B(a,\delta)$	$\forall c > 0\ \exists \delta > 0$: $\|f(x)\| \le c\,\|g(x)\|$ für $\|x-a| < \delta$
$\mathcal{N}(a)$ ohne a	$B(a,\delta)$ ohne a	dasselbe, nur für $0 < \|x-a| < \delta$
$\mathrm{atTop},\ x \to \infty$	ein Endstück $[N,\infty)$	$\forall c > 0\ \exists N$: $\|f(x)\| \le c\,\|g(x)\|$ für $x \ge N$

- **Ohne a:** x läuft gegen a, ist aber nie gleich a – die Kugel hat in der Mitte ein Loch. Nötig bei $\frac{f(x)-f(a)}{x-a}$, das bei $x = a$ nicht erklärt ist.
- Zu jedem c gehört ein eigenes δ bzw. N: Je kleiner c, desto kleiner die Kugel und desto später das Endstück. Dabei misst c das Verhältnis zweier Größen, keinen Abstand wie ε.
- Mit $g \equiv 1$: $f = o(1)$ längs l heißt $f \to 0$ längs l.
- Für Folgen, $l = \mathrm{atTop}$ auf $\mathbb{N}$: die o-Notation der Laufzeitanalyse, $n = o(n^2)$.

Warum ohne Teilen?

- **Wo man teilen kann, ist es dasselbe.** Ist g schließlich $\neq 0$, so gilt: $f = o(g) \iff f/g \to 0$. In Mathlib ist das ein Satz, nicht die Definition.
- **Bei der Ableitung kann man nicht überall teilen.** Dort ist $g(y) = y - x_0$, und das ist bei $y = x_0$ null. Wer teilt, muss $y = x_0$ ausnehmen. Mit dem Faktor c gilt die Ungleichung bei $y = x$ von selbst, denn auch der Fehler ist dort 0.
- **In mehreren Veränderlichen kann man gar nicht teilen.** Durch einen Vektor h teilt man nicht – die Definition braucht nur Normen.

Beispiel ($(y - x_0)^2 = o(y - x_0)$ längs $\mathcal{N}(x_0)$, zweimal)

- **Mit Teilen:** Für $y \neq x_0$ ist $\frac{(y-x_0)^2}{y-x_0} = y - x_0 \to 0$.
- **Ohne Teilen:** Zu $c > 0$ ist $|y - x_0|^2 \leq c\,|y - x_0|$ auf der ganzen Kugel $|y - x_0| < c$ – auch bei $y = x_0$.

Satz (Summenregel)

Sind $f_1 = o(g)$ und $f_2 = o(g)$ längs l, so ist $f_1 + f_2 = o(g)$ längs l.

Beweis. Sei $c > 0$.

1. Mit $c/2$ statt c sind die Mengen $U_1 = \{\, \|f_1\| \le \frac{c}{2}\,\|g\| \,\}$ und $U_2 = \{\, \|f_2\| \le \frac{c}{2}\,\|g\| \,\}$ groß.
2. Der Schnitt zweier großer Mengen ist groß (Axiom (iii)): Auf $U_1 \cap U_2$ ist $\|f_1 + f_2\| \le \|f_1\| + \|f_2\| \le c\,\|g\|$.
3. Die Menge, auf der $\|f_1 + f_2\| \le c\,\|g\|$ gilt, enthält $U_1 \cap U_2$. Obermengen großer Mengen sind groß (Axiom (ii)), also ist sie groß. □

- Klassisch: ε halbieren, dann das kleinere δ oder das größere N nehmen. Hier ist das Axiom (iii) – einmal bewiesen, für jeden Filter.
- Ebenso: konstante Vielfache von $o(g)$ sind $o(g)$, und aus $f = o(g)$ und $g = O(h)$ folgt $f = o(h)$.

Landau-Symbole in Lean

- **Die Definition** ist in Mathlib die mit dem Faktor c: zu jedem $c > 0$ die Ungleichung, schließlich längs des Filters. Der Filter steht in der Aussage selbst.
- **Die Beispiele, von Hand:** $x^2 = o(x)$ bei 0 mit der Kugel vom Radius c; $x = o(x^2)$ bei $+\infty$ mit dem Endstück ab $1/c$. Dass x^2 bei $+\infty$ nicht $o(x)$ ist, braucht einen Punkt, an dem zwei Aussagen zugleich gelten – Lean nimmt ihn aus dem Schnitt zweier großer Mengen.
- **Die Summenregel, von Hand:** Den Schnitt der beiden großen Mengen bildet eine einzige Taktik. Danach bleibt die Dreiecksungleichung.
- **Mit Teilen:** Ist g schließlich $\neq 0$, ist $f = o(g) \iff f/g \to 0$ ein Satz aus Mathlib.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: $x = o(x^2)$ bei $+\infty$ – das Endstück ab $1/c$; in der Summenregel das Ziel vor und nach dem Schnitt

Vorlesung 5

Ableitung in einer Variablen

Die Definition

Durch einen Vektor kann man nicht teilen. Statt des Differenzenquotienten nimmt man die *lineare Approximation*, mit einer Norm als Maß für den Fehler.

Definition (Ableitung)

f hat in x_0 die Ableitung $f'(x_0)$, wenn

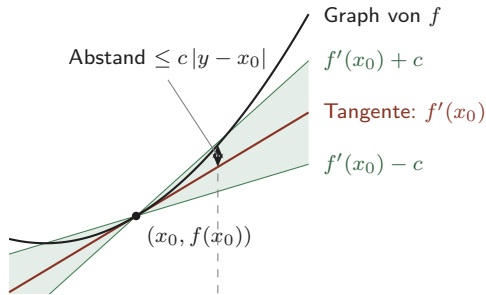
$$f(y) - f(x_0) - f'(x_0)\,(y - x_0) = o(y - x_0) \qquad \text{längs } \mathcal{N}(x_0).$$

- **Zur Erinnerung:** $\mathcal{N}(x_0)$ = Umgebungen von x_0 (groß: enthält eine Kugel um x_0); „längs $\mathcal{N}(x_0)$“ heißt y nahe bei x_0.
- Ausgeschrieben: Zu jedem $c > 0$ gibt es ein $\delta > 0$ mit $|f(y) - f(x_0) - f'(x_0)(y - x_0)| \le c\,|y - x_0|$ für $|y - x_0| < \delta$ – die ε-δ-Form, mit c statt ε.
- In einer Variablen ist das die gewöhnliche Ableitung: Für $y \neq x_0$ darf man teilen,

$$\frac{f(y) - f(x_0) - f'(x_0)(y - x_0)}{y - x_0} = \frac{f(y) - f(x_0)}{y - x_0} - f'(x_0) \;\to\; 0.$$

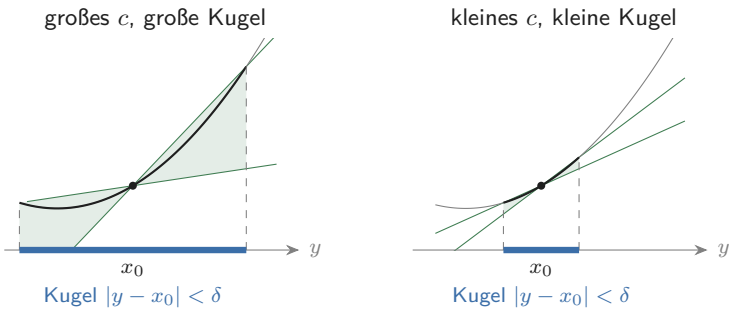
Geometrisch: der Keil um die Tangente

- Die Tangente bei x_0: Gerade durch $(x_0, f(x_0))$ mit Steigung $f'(x_0)$. Bei y hat sie die Höhe $f(x_0) + f'(x_0)\,(y - x_0)$.
- $|f(y) - f(x_0) - f'(x_0)(y - x_0)|$ ist der senkrechte **Abstand** von Graph und Tangente bei y.
- Er darf höchstens $c\,|y - x_0|$ sein, wachsend mit dem Abstand von x_0: der Bereich zwischen *zwei Geraden* durch $(x_0, f(x_0))$ mit den Steigungen $f'(x_0) \pm c$. Ein **Keil**, der sich vom Punkt aus öffnet.



„Schließlich“ bei der Ableitung: zu jedem c eine Kugel

Der Graph liegt im Keil um die Tangente (vorige Folie). „Schließlich längs $\mathcal{N}(x_0)$“ heißt: für alle y in einer Kugel um x_0.



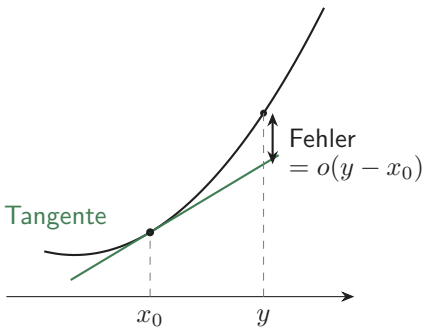
Je schmaler der Keil, desto kleiner die Kugel – aber zu jedem c gibt es eine.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: die ε-δ-Form der Ableitung

Die Gerade, die am besten passt

Die Gerade, die am besten passt

- Gerade durch den Punkt bei x_0; der Fehler ist der senkrechte Abstand zwischen Kurve und Gerade.
- Für *jede* solche Gerade geht er gegen null, wenn $y \to x_0$ – nichts Besonderes.
- Bei der Tangente geht er *schneller* gegen null als $y - x_0$: Das heißt $o(y - x_0)$. Das schafft nur eine Gerade, ihre Steigung ist die Ableitung $f'(x_0)$.



Vorgerechnet: $f(y) = y^2$

Behauptung: $f(y) = y^2$ hat in x_0 die Ableitung $f'(x_0) = 2x_0$.

1. **Fehler ausrechnen.**
   $f(y) - f(x_0) - (y - x_0) \cdot 2x_0 = y^2 - x_0^2 - 2x_0 y + 2x_0^2 = (y - x_0)^2$.
2. **Durch $y - x_0$ teilen.** $\dfrac{(y - x_0)^2}{y - x_0} = y - x_0 \to 0$. Der Fehler ist $o(y - x_0)$.
3. **Jede andere Steigung $s \neq 2x_0$ scheitert.**
   $f(y) - f(x_0) - (y - x_0)\, s = (y - x_0)^2 + (2x_0 - s)(y - x_0)$.
   Geteilt durch $y - x_0$ geht das gegen $2x_0 - s \neq 0$.

Der Fehler der anderen Geraden geht auch gegen null – aber nicht schneller als $y - x_0$. Nur die Tangente schafft $o(y - x_0)$. Schritt 2 geht auch ohne Teilen, genau nach der Definition von o längs $\mathcal{N}(x_0)$: Zu jedem $c > 0$ ist $(y - x_0)^2 \leq c\,|y - x_0|$ auf der Kugel $|y - x_0| < c$.

Fermat: Am lokalen Minimum ist $f' = 0$

Satz (Fermat). Hat f in a ein lokales Minimum und die Ableitung f', so ist $f' = 0$.

1. **Steigungen.** $s(x) = \big(f(x) - f(a)\big)/(x - a)$ geht für $x \to a$, $x \neq a$ gegen f'.
2. **Vorzeichen.** Nahe a ist $f(x) \geq f(a)$: links von a ist $s(x) \leq 0$, rechts $s(x) \geq 0$.
3. **Grenzübergang.** Grenzwerte erhalten $\leq$: links $f' \leq 0$, rechts $f' \geq 0$, also $f' = 0$.

In Lean derselbe Beweis. Schritt 1 ist ein Satz aus Mathlib: Die Steigungen streben gegen f', längs der Umgebungen von a ohne a selbst. Für Schritt 3 schränkt man diesen Filter auf die linke bzw. rechte Seite ein. Dort gilt das Vorzeichen aus Schritt 2 schließlich, und Grenzwerte erhalten $\leq$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: Fermat in den drei Schritten von Hand

Pause

Danach: Mehrere Veränderliche: Jacobi-Matrix, Kettenregel, Hesse-Matrix

Vorlesung 5

Mehrere Veränderliche

Mehrere Veränderliche: Die Ableitung ist eine Matrix

Für $f : \mathbb{R}^n \to \mathbb{R}^m$ bleibt die Definition dieselbe – nur ist die Ableitung jetzt eine lineare Abbildung, und durch h teilen kann man nicht.

Definition (Ableitung in mehreren Veränderlichen)

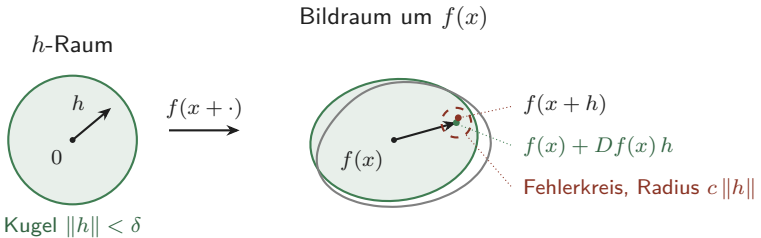
f hat in x die Ableitung $Df(x)$, eine lineare Abbildung $\mathbb{R}^n \to \mathbb{R}^m$, wenn

$$f(x+h) - f(x) - Df(x)\,h = o(h) \qquad \text{längs } \mathcal{N}(0).$$

- **Zur Erinnerung:** $\mathcal{N}(0)$ = Umgebungen von 0 im h-Raum; groß heißt, eine Kugel $\|h\| < \delta$ zu enthalten. „Längs $\mathcal{N}(0)$“ heißt: für h nahe bei 0, also $x+h$ nahe bei x.
- Eine lineare Abbildung $\mathbb{R}^n \to \mathbb{R}^m$ ist eine $m \times n$-Matrix: die *Jacobi-Matrix* $J_f(x)$.
- Ihre Spalte j ist $Df(x)\,e_j$: wie sich f ändert, wenn sich nur die j-te Koordinate bewegt. Zeile i gehört zur Komponente f_i.
- Für $f : \mathbb{R}^n \to \mathbb{R}$ ist $J_f(x)$ eine Zeile, für eine Kurve $f : \mathbb{R} \to \mathbb{R}^m$ eine Spalte, der Geschwindigkeitsvektor.

„Schließlich“ bei der Ableitung: mehrere Veränderliche

$$\underbrace{\forall c > 0}_{\text{jedes } c \text{ (das } o\text{)}} \quad \underbrace{\exists \delta > 0 \, \forall h, \ \|h\| < \delta}_{\text{„schließlich längs } \mathcal{N}(0)\text{“}} : \quad \|f(x+h) - f(x) - Df(x)\,h\| \le c\,\|h\|$$



Das Bild von $x + h$ liegt im Fehlerkreis; zu kleinerem c gehört eine kleinere Kugel.
Dasselbe Bild wie der Keil in einer Variablen: Dort ist der Fehlerkreis ein Intervall der Länge $2c\,|h|$ um die Tangente; für alle h übereinander (h waagerecht) ergibt das den Keil. Hier zeichnet man ein h nach dem anderen.

Partielle Ableitungen

Definition (Richtungsableitung, partielle Ableitung)

Sei $f : \mathbb{R}^n \to \mathbb{R}^m$, $x, v \in \mathbb{R}^n$. Die *Richtungsableitung* von f in x in Richtung v ist

$$\partial_v f(x) = \lim_{t \to 0} \frac{f(x + tv) - f(x)}{t},$$

falls der Grenzwert existiert – die Ableitung der Schnittkurve $t \mapsto f(x + tv)$ in 0. Für $v = e_j$ heißt sie *partielle Ableitung* $\partial f / \partial x_j\,(x)$: Nur die j-te Koordinate bewegt sich.

Beispiel ($f(x, y) = x^2 y$)

y wie eine Konstante behandeln: $\partial f / \partial x = 2xy$; ebenso $\partial f / \partial y = x^2$. In $(1, 2)$ also 4 und 1.

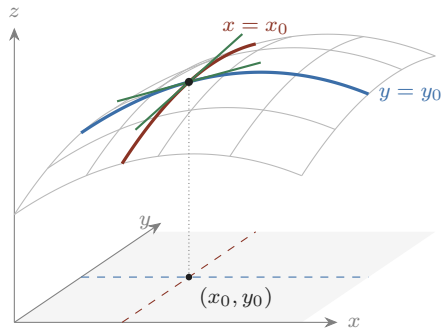
Eine partielle Ableitung ist eine Ableitung in *einer* Variablen – alle Regeln von dort gelten. Sie sieht von f nur eine Gerade durch x.

Partielle Ableitung: die Steigung einer Schnittkurve

Den Graphen anschneiden

Hält man $y = y_0$ fest, schneidet man den Graphen von f längs einer Kurve (blau). Ihre Steigung in x_0 ist $\partial f/\partial x\,(x_0, y_0)$. Hält man $x = x_0$ fest, entsteht die rote Kurve, mit der Steigung $\partial f/\partial y\,(x_0, y_0)$.

Die grünen Tangenten spannen die Tangentialebene auf – wenn es sie gibt. Zwei Richtungen, zwei Zahlen: Was zwischen den Richtungen geschieht, sehen die partiellen Ableitungen nicht.



Satz (Ableitung und partielle Ableitungen)

Sei $f : \mathbb{R}^n \to \mathbb{R}^m$ und $x \in \mathbb{R}^n$.

(a) Ist f in x differenzierbar, so existiert jede Richtungsableitung, und $\partial_v f(x) = Df(x)\, v$. Die j-te Spalte der Jacobi-Matrix ist die partielle Ableitung: $J_f(x) = \left(\partial f_i / \partial x_j\,(x)\right)_{i,j}$.

(b) Existieren die partiellen Ableitungen in einer Umgebung von x und sind sie in x stetig, so ist f in x differenzierbar.

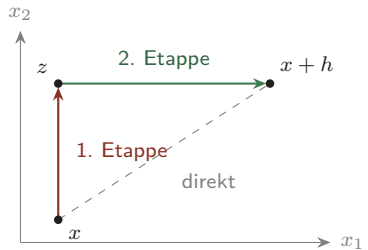
Beweis von (a), mit o. Nach Definition ist $f(x+h) - f(x) - Df(x)\,h = o(h)$ längs $\mathcal{N}(0)$. Setzt man $h = tv$ ein – für $t \to 0$ geht $tv \to 0$ –, bleibt

$$f(x+tv) - f(x) - t\,Df(x)\,v = o(tv) = o(t),$$

denn $\|tv\| = |t|\,\|v\|$. Geteilt durch t: $\frac{f(x+tv)-f(x)}{t} \to Df(x)\,v$. □

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: dieser Beweis in Lean, Schritt für Schritt

Beweis von (b): in zwei Etappen von x nach $x + h$



Man geht in zwei Etappen über den Zwischenpunkt $z = (x_1,\ x_2 + h_2)$:

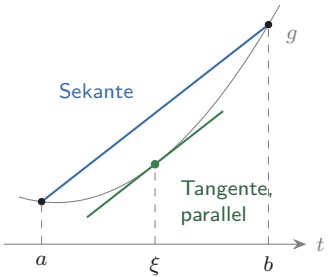
1. erst nur die zweite Koordinate: $x \to z$,
2. dann nur die erste: $z \to x + h$.

Der Zuwachs ist die Summe der Zuwächse beider Etappen, denn $f(z)$ kommt einmal mit $-$ und einmal mit $+$ vor und hebt sich weg:

$$f(x+h) - f(x) = \underbrace{\big[f(x+h) - f(z)\big]}_{\text{2. Etappe}} + \underbrace{\big[f(z) - f(x)\big]}_{\text{1. Etappe}}.$$

Auf jeder Etappe ändert sich nur *eine* Koordinate: Jede Klammer ist die Differenz einer Funktion von *einer* Variablen – dafür gilt der Mittelwertsatz.

Der Mittelwertsatz in einer Variablen



Satz (Mittelwertsatz)

Ist g auf $[a, b]$ stetig und auf (a, b) differenzierbar, so gibt es ein $\xi \in (a, b)$ mit

$$g(b) - g(a) = g'(\xi)\,(b - a).$$

Anschaulich: Irgendwo ist die Tangente parallel zur Sekante.

Wozu hier: Der Zuwachs ist „Steigung an einer Zwischenstelle mal Länge“ – exakt, nicht nur näherungsweise. Für die Klammer $f(x_1 + h_1, x_2 + h_2) - f(x_1, x_2 + h_2)$ setzt man $g(t) = f(x_1 + t,\ x_2 + h_2)$ auf $[0, h_1]$. Dann ist $g'(t) = \partial_1 f(x_1 + t,\ x_2 + h_2)$, und der Satz liefert einen Punkt ξ auf der Strecke mit $g(h_1) - g(0) = \partial_1 f(\xi)\, h_1$.

Beweis von (b): eine Koordinate nach der anderen

Für $n = 2$ und reellwertiges f; sonst je Komponente und je Koordinate ebenso. Sei $h = (h_1, h_2)$ klein.

1. **Zerlegen** in die zwei Etappen von eben, mit $z = (x_1, x_2 + h_2)$:

$$f(x+h) - f(x) = \big[f(x_1+h_1, x_2+h_2) - f(x_1, x_2+h_2)\big] + \big[f(x_1, x_2+h_2) - f(x_1, x_2)\big].$$

2. **Mittelwertsatz** in einer Variablen, je Klammer: Es gibt einen Punkt ξ auf der Strecke von z nach $x + h$ und einen Punkt η auf der Strecke von x nach z mit

$$f(x + h) - f(x) = \partial_1 f(\xi)\, h_1 + \partial_2 f(\eta)\, h_2.$$

Das ist schon fast Jh mit $J = \big(\partial_1 f(x),\ \partial_2 f(x)\big)$ – nur steht $\partial_i f$ an den Zwischenstellen ξ, η statt in x. Wie groß der Unterschied ist, schätzt die nächste Folie ab.

Beweis von (b): den Rest abschätzen

Zu zeigen ist: Der Rest $r(h) = f(x+h) - f(x) - Jh$ ist $o(h)$, mit $J = \big(\partial_1 f(x),\ \partial_2 f(x)\big)$.

1. **Rest bilden.** Wegen $Jh = \partial_1 f(x)\, h_1 + \partial_2 f(x)\, h_2$ und Schritt 2 ist

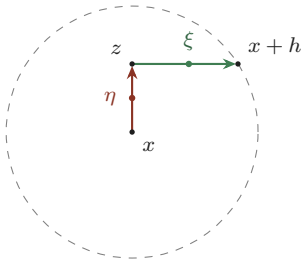
$$r(h) = \big[\partial_1 f(\xi) - \partial_1 f(x)\big]\, h_1 + \big[\partial_2 f(\eta) - \partial_2 f(x)\big]\, h_2.$$

2. **Beträge.** Jede Koordinate ist höchstens $\|h\|$, also

$$|r(h)| \le \Big(\underbrace{|\partial_1 f(\xi) - \partial_1 f(x)| + |\partial_2 f(\eta) - \partial_2 f(x)|}_{\text{muss klein werden}} \Big)\, \|h\|.$$

Die Klammer vergleicht die partiellen Ableitungen an den Zwischenstellen ξ, η mit denen in x. Dass sie für kleine h klein ist, ist genau die Stetigkeit – nächste Folie.

Beweis von (b): hier wird die Stetigkeit gebraucht



Kugel um x, Radius $\|h\|$

3. **Die Klammer klein machen.** Sei $c > 0$. Weil $\partial_1 f, \partial_2 f$ in x stetig sind, gibt es ein $\delta > 0$ mit $|\partial_i f(w) - \partial_i f(x)| < c/2$ für $\|w - x\| < \delta$.
4. Ist $\|h\| < \delta$, so sind ξ und η höchstens $\|h\|$ von x entfernt (Bild), also liegt die Klammer unter $c/2 + c/2 = c$.
5. **Fertig:** Für $\|h\| < \delta$ gilt $|r(h)| \le c\,\|h\|$ – zu jedem c ein δ: Der Rest ist $o(h)$. □

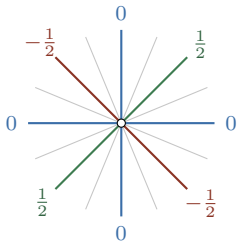
Was genau gebraucht wird

- Die $\partial_i f$ *existieren* um x: für den Mittelwertsatz an den Zwischenstellen ξ, η.
- Die $\partial_i f$ sind in x *stetig*: damit die Klammer gegen 0 geht. Ohne das scheitert genau dieser Schritt – siehe $\frac{xy}{x^2+y^2}$.

Partielle Ableitungen allein reichen nicht

$$f(x,y) = \frac{xy}{x^2+y^2}, \qquad f(0,0) = 0.$$

- Auf beiden Achsen ist $f = 0$: Beide partiellen Ableitungen in 0 existieren und sind 0.
- In Polarkoordinaten ist $f = \cos\varphi \, \sin\varphi = \frac{1}{2}\sin 2\varphi$: auf jedem Strahl konstant, auf der Diagonalen $\frac{1}{2}$. In 0 ist f nicht einmal stetig – erst recht nicht differenzierbar.



f auf den Strahlen: $\frac{1}{2}\sin 2\varphi$

Auch alle Richtungen reichen nicht: $g(x,y) = \frac{x^2 y}{x^2+y^2}$, $g(0,0) = 0$, ist stetig, und $\partial_v g(0) = \frac{v_1^2 v_2}{v_1^2+v_2^2}$ existiert für jedes v – ist aber nicht linear in v. Nach (a) ist g in 0 nicht differenzierbar.

Differenzierbar heißt: *eine* lineare Abbildung für alle Richtungen zugleich, mit einem Fehler $o(h)$.

Vorgerechnet: $f(x,y) = (xy,\ x+y)$

1. **Differenz.** Mit $h = (h_1, h_2)$:
$$f(x+h_1, y+h_2) - f(x,y) = \begin{pmatrix} y\,h_1 + x\,h_2 + h_1 h_2 \\ h_1 + h_2 \end{pmatrix}.$$
2. **Linearer Teil und Rest.**
$$\begin{pmatrix} y\,h_1 + x\,h_2 + h_1 h_2 \\ h_1 + h_2 \end{pmatrix} = \underbrace{\begin{pmatrix} y & x \\ 1 & 1 \end{pmatrix}\begin{pmatrix} h_1 \\ h_2 \end{pmatrix}}_{\text{linear in } h} + \underbrace{\begin{pmatrix} h_1 h_2 \\ 0 \end{pmatrix}}_{\text{Rest } r(h)}.$$
3. **Der Rest ist $o(h)$.** $\|r(h)\| = |h_1 h_2| \le \frac{1}{2}\|h\|^2 \le c\,\|h\|$, sobald $\|h\| \le 2c$.

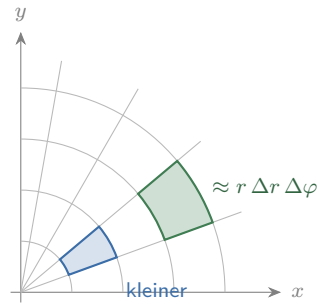
Also ist $J_f(x,y) = \begin{pmatrix} y & x \\ 1 & 1 \end{pmatrix}$. **Probe** mit den partiellen Ableitungen: $\partial_x(xy) = y$, $\partial_y(xy) = x$, $\partial_x(x+y) = \partial_y(x+y) = 1$ – dieselbe Matrix, wie es Teil (a) verlangt. Sie sind stetig: Teil (b) gibt die Differenzierbarkeit auch so.

Polarkoordinaten

$P(r, \varphi) = (r\cos\varphi,\ r\sin\varphi)$, Spalte für Spalte partiell abgeleitet:

$$J_P(r,\varphi) = \begin{pmatrix} \cos\varphi & -r\sin\varphi \\ \sin\varphi & r\cos\varphi \end{pmatrix}.$$

- Spalte 1 ($\partial P/\partial r$): Einheitsvektor nach außen. Spalte 2 ($\partial P/\partial\varphi$): tangential, Länge r.
- $\det J_P = r\cos^2\varphi + r\sin^2\varphi = r$.



Gleiche Δr und $\Delta\varphi$: außen größere Stücke.

Der Flächenfaktor

Ein kleines Rechteck $\Delta r \times \Delta\varphi$ wird ein Stück Kreisring der Fläche $\approx r\,\Delta r\,\Delta\varphi$: $\det J_P$ ist der Faktor, um den P kleine Flächen streckt.

Die Kettenregel: Matrizen multiplizieren

Satz (Kettenregel)

Hat f in x die Ableitung $Df(x)$ und g in $f(x)$ die Ableitung $Dg(f(x))$, so ist

$$D(g \circ f)(x) = Dg(f(x))\, Df(x), \qquad J_{g\circ f}(x) = J_g(f(x)) \cdot J_f(x).$$

Warum, mit o gerechnet: $k = f(x+h) - f(x) = Df(x)\,h + o(h)$ ist höchstens ein festes Vielfaches von $\|h\|$. Also $g(f(x)+k) - g(f(x)) = Dg\,k + o(k) = Dg\,Df\,h + o(h)$: Konstante mal $o(h)$ ist $o(h)$, und $o(k)$ ist $o(h)$, wenn k nicht schneller wächst als h.

Beispiel ($g(u,v) = u^2 + v^2$ nach Polarkoordinaten)

$g(P(r,\varphi)) = r^2$, direkt abgeleitet also $J = (2r,\ 0)$. Mit der Kettenregel:

$$(2r\cos\varphi,\ 2r\sin\varphi)\begin{pmatrix}\cos\varphi & -r\sin\varphi\\ \sin\varphi & r\cos\varphi\end{pmatrix} = (2r\,(\cos^2\varphi + \sin^2\varphi),\ 0) = (2r,\ 0).$$

Gradient und Hesse-Matrix

Für $f : \mathbb{R}^n \to \mathbb{R}$ ist $J_f(x)$ eine Zeile. Als Spalte geschrieben ist sie der *Gradient*: $Df(x)\,h = \langle \nabla f(x), h \rangle$. Die *Hesse-Matrix* $H_f(x)$ ist die Jacobi-Matrix des Gradienten, also die Matrix der zweiten partiellen Ableitungen $\partial^2 f / \partial x_i \partial x_j$.

Beispiel ($f(x,y) = x^2 + xy + y^2 - x - y$)

1. $\nabla f(x,y) = (2x + y - 1,\ x + 2y - 1)$ – die partiellen Ableitungen.
2. $H_f = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, konstant, mit den Eigenwerten 3 und 1 zu den Richtungen $(1,1)$ und $(1,-1)$.
3. $\nabla f = 0$ nur bei $v^* = (\tfrac{1}{3}, \tfrac{1}{3})$. Dort ist f minimal, denn $f(v) = f(v^*) + \tfrac{1}{2}\,(v - v^*)^\top H_f\,(v - v^*)$, und beide Eigenwerte sind positiv.

Allgemein: $f(x) = \tfrac{1}{2}\,x^\top A x - b^\top x$ mit symmetrischem A hat $\nabla f(x) = Ax - b$ und $H_f = A$.

Zusammenfassung

- Landau-Symbole: $f = o(g)$ längs l heißt, zu jedem $c > 0$ ist $\|f\| \leq c\,\|g\|$ schließlich. Kein Teilen; der Filter entscheidet mit; die Summenregel ist Axiom (iii).
- Ableitung: Fehler $= o(y - x_0)$ längs $\mathcal{N}(x_0)$. Die Zahl $f'(x_0)$ ist in Mathlib total, mit Junk-Wert 0. Am lokalen Minimum ist $f' = 0$ (Fermat).
- Mehrere Veränderliche: Die Ableitung ist die Jacobi-Matrix. Ihre Spalten sind die partiellen Ableitungen; stetige partielle Ableitungen liefern Differenzierbarkeit, partielle Ableitungen allein nicht. Die Kettenregel multipliziert Jacobi-Matrizen.
- Gradient und Hesse-Matrix: die Jacobi-Zeile von f und die Jacobi-Matrix des Gradienten, die Matrix der zweiten partiellen Ableitungen.

Nächstes Mal: Optimierung

- Die Taylorformel in mehreren Veränderlichen: auf der Strecke von p nach $p + h$ wird sie zur Taylorformel in einer Variablen.
- Hoch-, Tief- und Sattelpunkte: Am lokalen Extremum ist $\nabla f = 0$, und die Hesse-Matrix entscheidet, was dort liegt – in zwei Dimensionen mit Determinante und Spur, in höheren mit den Eigenwerten.
- Gradientenabstieg mit Konvergenzbeweis, in einer und in zwei Variablen.
- Optima unter Nebenbedingungen mit Lagrange-Multiplikatoren.

Lean live: Blatt 5, Teil B

- `lean/Blatt05.lean` in VS Code öffnen und jedes sorry durch einen Beweis ersetzen.
- Die Begriffe sind die von heute: Klein-o längs eines Filters, die Ableitung über den Fehler der Tangente, partielle Ableitungen über Schnittkurven, Jacobi-Matrizen als lineare Abbildungen.
- Das Infofenster zeigt nach jedem Schritt den Beweiszustand: Annahmen und Ziel.
- Anfangen mit B1: „schließlich“ längs atTop und längs einer Umgebung.

Live in Lean `code/Vorlesung05.lean` – zum Nachschlagen: alle Beweise von heute, in der Reihenfolge der Folien