

Angewandte Mathematik

Vorlesung 5 von 10

Ableitung und Optimierung

Skript: Abschnitte 4.4–4.6

Ablauf heute

0:00	Rückblick: Räume und Konvergenz	Vorlesung 4
0:08	Teil 1: Landau-Symbole – o längs eines Filters	Skript 4.4
0:26	Ableitung in einer Variablen: die beste Gerade, Fermat	Skript 4.4
0:40	Mehrere Veränderliche: Ableitung und partielle Ableitungen	Skript 4.4
0:58	Jacobi-Matrix: Beispiele, Kettenregel, Hesse-Matrix	Skript 4.4
1:12	*Pause*	
1:27	Teil 2: Gradientenabstieg – in einer und in zwei Variablen	Skript 4.5
2:02	Optima unter Nebenbedingungen: Lagrange	Skript 4.6
2:20	Zusammenfassung und Ausblick	
2:30	Ende	

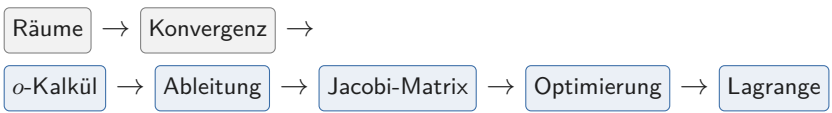
Rückblick: Vorlesung 4

- **Vier Stufen:** topologischer Raum (nahe?), metrischer Raum (wie weit?), normierter Raum (wie lang? $x + y$?), Innenproduktraum (welcher Winkel?). Jede Stufe liefert die darunter mit.
- **Filter:** ein System „großer“ Mengen. Das Ganze ist groß, Obermengen großer Mengen sind groß, zwei große Mengen haben großen Schnitt.
- $\mathcal{N}(a)$ schrumpft auf den Punkt a, atTop auf nichts: der Punkt „$+\infty$“, den es nicht gibt.
- **Schließlich:** $P(x)$ gilt schließlich längs F, wenn $\{x \mid P(x)\}$ groß ist. Mathlib hat dafür einen eigenen Quantor: „für schließlich alle x längs F“.
- **Tendsto:** f strebt längs F gegen G, wenn Urbilder großer Mengen groß sind. *Ein* Begriff für alle Grenzwerte – für Folgen genau die ε-N-Definition.
- **Summenregel:** einmal bewiesen, für jeden Filter – ε halbieren; das Maximum der N steckt im dritten Axiom.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.2: der Quantor, verglichen mit „für alle“

Was worauf aufbaut

Die Begriffe bauen aufeinander auf:



Die Landau-Symbole wären ohne Filter nicht zu erklären, die Ableitung nicht ohne Landau-Symbole. Und jeder Begriff hat ein Minimum an Struktur, mit dem er auskommt:

Thema	**braucht**	**Stufe**
Landau-Symbole	einen Filter + Größen vergleichen	normiert
Ableitung, Jacobi-Matrix	dazu Addition: Näherung = Differenz	normiert
Gradient, Gradientenabstieg	ein Skalarprodukt	Innenproduktraum

Vorlesung 5

Landau-Symbole: Vergleichen längs eines Filters

Vernachlässigbar klein

Klassisch heißt $f = o(g)$ für $x \to a$: $\dfrac{f(x)}{g(x)} \to 0$. Das hat zwei Haken:

- **Man teilt.** Wird g nahe a null, ist der Quotient nicht erklärt – und durch einen Vektor kann man gar nicht teilen.
- **Jedes „$x \to \ldots$“ braucht eine eigene Fassung:** gegen einen Punkt, von rechts, gegen ∞, für Folgen.

Mathlib behebt beides auf einmal:

- **Statt zu teilen**, vergleicht man mit einem Faktor: $\|f(x)\| \le c\,\|g(x)\|$.
- **Statt „$x \to a$“** nimmt man einen *Filter* l: ein System „großer“ Mengen mit
  (i) das Ganze ist groß,
  (ii) Obermengen großer Mengen sind groß,
  (iii) der Schnitt zweier großer Mengen ist groß.

  Eine Aussage gilt *schließlich* längs l, wenn die Menge der Punkte, an denen sie gilt, groß ist.

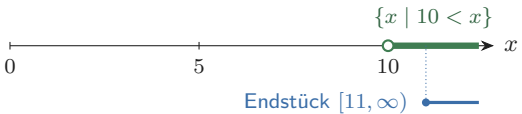
„Schließlich“: die Menge, auf der P gilt

Definition (Schließlich)

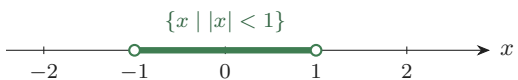
$P(x)$ gilt *schließlich* längs l, wenn die Menge $\{\, x \mid P(x) \,\}$ groß ist, also in l liegt.

Groß heißt bei atTop: enthält ein Endstück; bei $\mathcal{N}(a)$: enthält eine Kugel um a. Beide Mengen im Bild sind groß. Was weit weg vom Ziel geschieht, zählt nicht.

$P(x)$: $10 < x$, längs atTop



$P(x)$: $|x| < 1$, längs $\mathcal{N}(0)$



selbst eine Kugel um 0

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.2: „schließlich“ als Mengenaussage, $\{x \mid 10 < x\}$ im Filter atTop und die Kugel um 0

Klein-o längs eines Filters

Definition (Landau-Symbole längs eines Filters)

Seien f, g Abbildungen von X in normierte Räume und l ein Filter auf X.

$$f = o(g) \text{ längs } l \iff \text{für } \textit{jedes } c > 0 \text{ gilt schließlich } \|f(x)\| \le c\,\|g(x)\|,$$
$$f = O(g) \text{ längs } l \iff \text{für } \textit{ein } c \text{ gilt schließlich } \|f(x)\| \le c\,\|g(x)\|.$$

Schließlich heißt: Die Menge $\{\, x : \|f(x)\| \le c\,\|g(x)\| \,\}$ ist groß.

- O: höchstens so groß wie g, bis auf einen festen Faktor. o: *jeder* noch so kleine Faktor reicht – gegen g ist f vernachlässigbar. So ist $3x = O(x)$, aber nicht $o(x)$.
- **Die Reihenfolge trägt die Bedeutung:** erst c, dann die große Menge. Je kleiner c, desto näher muss man herangehen – zu jedem c eine eigene große Menge.
- Das $=$ ist keine Gleichung: Aus $x^2 = o(x)$ und $x^3 = o(x)$ folgt nicht $x^2 = x^3$. Gemeint ist $f \in o(g)$.

Was „schließlich“ heißt, sagt der Filter

Setzt man die wichtigsten Filter ein, kommen die vertrauten Formen heraus (c statt ε):

Filter	**groß heißt: enthält**	$f = o(g)$ **heißt ausgeschrieben**
$\mathcal{N}(a),\ x \to a$	eine Kugel $B(a,\delta)$	$\forall c > 0\ \exists \delta > 0$: $\|f(x)\| \le c\,\|g(x)\|$ für $\|x-a| < \delta$
$\mathcal{N}(a)$ ohne a	$B(a,\delta)$ ohne a	dasselbe, nur für $0 < \|x-a| < \delta$
$\mathrm{atTop},\ x \to \infty$	ein Endstück $[N,\infty)$	$\forall c > 0\ \exists N$: $\|f(x)\| \le c\,\|g(x)\|$ für $x \ge N$

- **Ohne a:** x läuft gegen a, ist aber nie gleich a – die Kugel hat in der Mitte ein Loch. Nötig bei $\frac{f(x)-f(a)}{x-a}$, das bei $x = a$ nicht erklärt ist.
- Zu jedem c gehört ein eigenes δ bzw. N: Je kleiner c, desto kleiner die Kugel und desto später das Endstück. Dabei misst c das Verhältnis zweier Größen, keinen Abstand wie ε.
- Mit $g \equiv 1$: $f = o(1)$ längs l heißt $f \to 0$ längs l.
- Für Folgen, $l = \mathrm{atTop}$ auf $\mathbb{N}$: die o-Notation der Laufzeitanalyse, $n = o(n^2)$.

Warum ohne Teilen?

- **Wo man teilen kann, ist es dasselbe.** Ist g schließlich $\neq 0$, so gilt: $f = o(g) \iff f/g \to 0$. In Mathlib ist das ein Satz, nicht die Definition.
- **Bei der Ableitung kann man nicht überall teilen.** Dort ist $g(y) = y - x_0$, und das ist bei $y = x_0$ null. Wer teilt, muss $y = x_0$ ausnehmen. Mit dem Faktor c gilt die Ungleichung bei $y = x$ von selbst, denn auch der Fehler ist dort 0.
- **In mehreren Veränderlichen kann man gar nicht teilen.** Durch einen Vektor h teilt man nicht – die Definition braucht nur Normen.

Beispiel ($(y - x_0)^2 = o(y - x_0)$ längs $\mathcal{N}(x_0)$, zweimal)

- **Mit Teilen:** Für $y \neq x_0$ ist $\frac{(y-x_0)^2}{y-x_0} = y - x_0 \to 0$.
- **Ohne Teilen:** Zu $c > 0$ ist $|y - x_0|^2 \leq c\,|y - x_0|$ auf der ganzen Kugel $|y - x_0| < c$ – auch bei $y = x_0$.

Satz (Summenregel)

Sind $f_1 = o(g)$ und $f_2 = o(g)$ längs l, so ist $f_1 + f_2 = o(g)$ längs l.

Beweis. Sei $c > 0$.

1. Mit $c/2$ statt c sind die Mengen $U_1 = \{\, \|f_1\| \le \frac{c}{2}\,\|g\| \,\}$ und $U_2 = \{\, \|f_2\| \le \frac{c}{2}\,\|g\| \,\}$ groß.
2. Der Schnitt zweier großer Mengen ist groß (Axiom (iii)): Auf $U_1 \cap U_2$ ist $\|f_1 + f_2\| \le \|f_1\| + \|f_2\| \le c\,\|g\|$.
3. Die Menge, auf der $\|f_1 + f_2\| \le c\,\|g\|$ gilt, enthält $U_1 \cap U_2$. Obermengen großer Mengen sind groß (Axiom (ii)), also ist sie groß. □

- Klassisch: ε halbieren, dann das kleinere δ oder das größere N nehmen. Hier ist das Axiom (iii) – einmal bewiesen, für jeden Filter.
- Ebenso: konstante Vielfache von $o(g)$ sind $o(g)$, und aus $f = o(g)$ und $g = O(h)$ folgt $f = o(h)$.

Landau-Symbole in Lean

- **Die Definition** ist in Mathlib die mit dem Faktor c: zu jedem $c > 0$ die Ungleichung, schließlich längs des Filters. Der Filter steht in der Aussage selbst.
- **Die Beispiele, von Hand:** $x^2 = o(x)$ bei 0 mit der Kugel vom Radius c; $x = o(x^2)$ bei $+\infty$ mit dem Endstück ab $1/c$. Dass x^2 bei $+\infty$ nicht $o(x)$ ist, braucht einen Punkt, an dem zwei Aussagen zugleich gelten – Lean nimmt ihn aus dem Schnitt zweier großer Mengen.
- **Die Summenregel, von Hand:** Den Schnitt der beiden großen Mengen bildet eine einzige Taktik. Danach bleibt die Dreiecksungleichung.
- **Mit Teilen:** Ist g schließlich $\neq 0$, ist $f = o(g) \iff f/g \to 0$ ein Satz aus Mathlib.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: $x = o(x^2)$ bei $+\infty$ – das Endstück ab $1/c$; in der Summenregel das Ziel vor und nach dem Schnitt

Vorlesung 5

Ableitung in einer Variablen

Die Definition

Durch einen Vektor kann man nicht teilen. Statt des Differenzenquotienten nimmt man die *lineare Approximation*, mit einer Norm als Maß für den Fehler.

Definition (Ableitung)

f hat in x_0 die Ableitung $f'(x_0)$, wenn

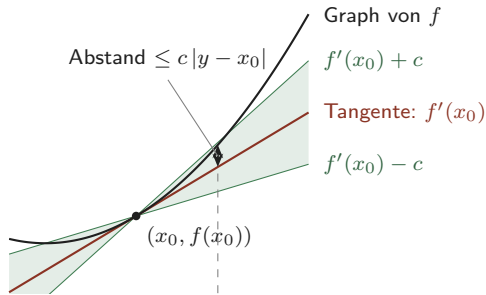
$$f(y) - f(x_0) - f'(x_0)\,(y - x_0) = o(y - x_0) \qquad \text{längs } \mathcal{N}(x_0).$$

- **Zur Erinnerung:** $\mathcal{N}(x_0)$ = Umgebungen von x_0 (groß: enthält eine Kugel um x_0); „längs $\mathcal{N}(x_0)$“ heißt y nahe bei x_0.
- Ausgeschrieben: Zu jedem $c > 0$ gibt es ein $\delta > 0$ mit $|f(y) - f(x_0) - f'(x_0)(y - x_0)| \le c\,|y - x_0|$ für $|y - x_0| < \delta$ – die ε-δ-Form, mit c statt ε.
- In einer Variablen ist das die gewöhnliche Ableitung: Für $y \neq x_0$ darf man teilen,

$$\frac{f(y) - f(x_0) - f'(x_0)(y - x_0)}{y - x_0} = \frac{f(y) - f(x_0)}{y - x_0} - f'(x_0) \;\to\; 0.$$

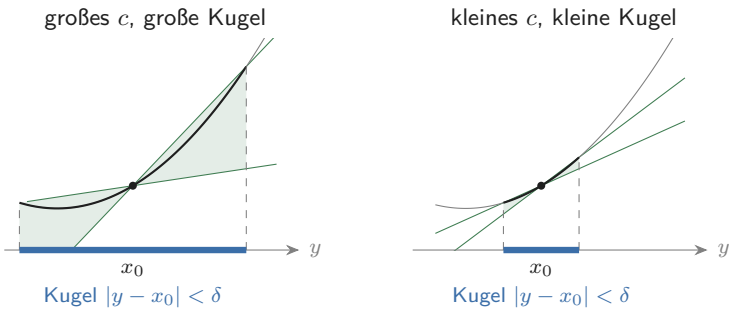
Geometrisch: der Keil um die Tangente

- Die Tangente bei x_0: Gerade durch $(x_0, f(x_0))$ mit Steigung $f'(x_0)$. Bei y hat sie die Höhe $f(x_0) + f'(x_0)\,(y - x_0)$.
- $|f(y) - f(x_0) - f'(x_0)(y - x_0)|$ ist der senkrechte **Abstand** von Graph und Tangente bei y.
- Er darf höchstens $c\,|y - x_0|$ sein, wachsend mit dem Abstand von x_0: der Bereich zwischen *zwei Geraden* durch $(x_0, f(x_0))$ mit den Steigungen $f'(x_0) \pm c$. Ein **Keil**, der sich vom Punkt aus öffnet.



„Schließlich“ bei der Ableitung: zu jedem c eine Kugel

Der Graph liegt im Keil um die Tangente (vorige Folie). „Schließlich längs $\mathcal{N}(x_0)$“ heißt: für alle y in einer Kugel um x_0.

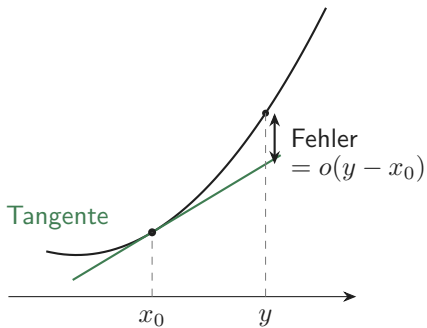


Je schmaler der Keil, desto kleiner die Kugel – aber zu jedem c gibt es eine.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: die ε-δ-Form der Ableitung

Die Gerade, die am besten passt

- Gerade durch den Punkt bei x_0; der Fehler ist der senkrechte Abstand zwischen Kurve und Gerade.
- Für *jede* solche Gerade geht er gegen null, wenn $y \to x_0$ – nichts Besonderes.
- Bei der Tangente geht er *schneller* gegen null als $y - x_0$: Das heißt $o(y - x_0)$. Das schafft nur eine Gerade, ihre Steigung ist die Ableitung $f'(x_0)$.



Vorgerechnet: $f(y) = y^2$

Behauptung: $f(y) = y^2$ hat in x_0 die Ableitung $f'(x_0) = 2x_0$.

1. **Fehler ausrechnen.**
   $f(y) - f(x_0) - (y - x_0) \cdot 2x_0 = y^2 - x_0^2 - 2x_0 y + 2x_0^2 = (y - x_0)^2$.
2. **Durch $y - x_0$ teilen.** $\dfrac{(y - x_0)^2}{y - x_0} = y - x_0 \to 0$. Der Fehler ist $o(y - x_0)$.
3. **Jede andere Steigung $s \neq 2x_0$ scheitert.**
   $f(y) - f(x_0) - (y - x_0)\, s = (y - x_0)^2 + (2x_0 - s)(y - x_0)$.
   Geteilt durch $y - x_0$ geht das gegen $2x_0 - s \neq 0$.

Der Fehler der anderen Geraden geht auch gegen null – aber nicht schneller als $y - x_0$. Nur die Tangente schafft $o(y - x_0)$. Schritt 2 geht auch ohne Teilen, genau nach der Definition von o längs $\mathcal{N}(x_0)$: Zu jedem $c > 0$ ist $(y - x_0)^2 \leq c\,|y - x_0|$ auf der Kugel $|y - x_0| < c$.

Fermat: Am lokalen Minimum ist $f' = 0$

Satz (Fermat). Hat f in a ein lokales Minimum und die Ableitung f', so ist $f' = 0$.

1. **Steigungen.** $s(x) = \big(f(x) - f(a)\big)/(x - a)$ geht für $x \to a$, $x \neq a$ gegen f'.
2. **Vorzeichen.** Nahe a ist $f(x) \geq f(a)$: links von a ist $s(x) \leq 0$, rechts $s(x) \geq 0$.
3. **Grenzübergang.** Grenzwerte erhalten $\leq$: links $f' \leq 0$, rechts $f' \geq 0$, also $f' = 0$.

In Lean derselbe Beweis. Schritt 1 ist ein Satz aus Mathlib: Die Steigungen streben gegen f', längs der Umgebungen von a ohne a selbst. Für Schritt 3 schränkt man diesen Filter auf die linke bzw. rechte Seite ein. Dort gilt das Vorzeichen aus Schritt 2 schließlich, und Grenzwerte erhalten $\leq$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: Fermat in den drei Schritten von Hand

Vorlesung 5

Mehrere Veränderliche

Mehrere Veränderliche: Die Ableitung ist eine Matrix

Für $f : \mathbb{R}^n \to \mathbb{R}^m$ bleibt die Definition dieselbe – nur ist die Ableitung jetzt eine lineare Abbildung, und durch h teilen kann man nicht.

Definition (Ableitung in mehreren Veränderlichen)

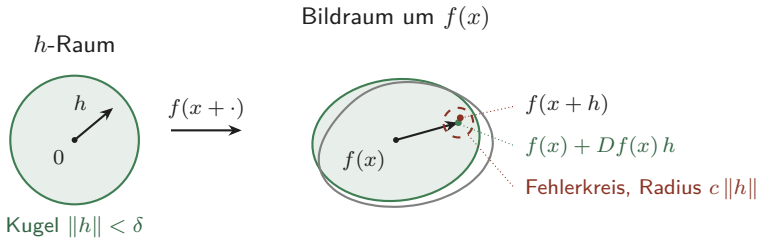
f hat in x die Ableitung $Df(x)$, eine lineare Abbildung $\mathbb{R}^n \to \mathbb{R}^m$, wenn

$$f(x+h) - f(x) - Df(x)\,h = o(h) \qquad \text{längs } \mathcal{N}(0).$$

- **Zur Erinnerung:** $\mathcal{N}(0)$ = Umgebungen von 0 im h-Raum; groß heißt, eine Kugel $\|h\| < \delta$ zu enthalten. „Längs $\mathcal{N}(0)$“ heißt: für h nahe bei 0, also $x+h$ nahe bei x.
- Eine lineare Abbildung $\mathbb{R}^n \to \mathbb{R}^m$ ist eine $m \times n$-Matrix: die *Jacobi-Matrix* $J_f(x)$.
- Ihre Spalte j ist $Df(x)\,e_j$: wie sich f ändert, wenn sich nur die j-te Koordinate bewegt. Zeile i gehört zur Komponente f_i.
- Für $f : \mathbb{R}^n \to \mathbb{R}$ ist $J_f(x)$ eine Zeile, für eine Kurve $f : \mathbb{R} \to \mathbb{R}^m$ eine Spalte, der Geschwindigkeitsvektor.

„Schließlich“ bei der Ableitung: mehrere Veränderliche

$$\underbrace{\forall c > 0}_{\text{jedes } c \text{ (das } o)} \quad \underbrace{\exists \delta > 0 \, \forall h, \ \|h\| < \delta}_{\text{„schließlich längs } \mathcal{N}(0)“} : \quad \|f(x+h) - f(x) - Df(x)\, h\| \le c\, \|h\|$$



Das Bild von $x + h$ liegt im Fehlerkreis; zu kleinerem c gehört eine kleinere Kugel.
Dasselbe Bild wie der Keil in einer Variablen: Dort ist der Fehlerkreis ein Intervall der Länge $2c\,|h|$ um die Tangente; für alle h übereinander (h waagerecht) ergibt das den Keil. Hier zeichnet man ein h nach dem anderen.

Definition (Richtungsableitung, partielle Ableitung)

Sei $f : \mathbb{R}^n \to \mathbb{R}^m$, $x, v \in \mathbb{R}^n$. Die *Richtungsableitung* von f in x in Richtung v ist

$$\partial_v f(x) = \lim_{t \to 0} \frac{f(x + tv) - f(x)}{t},$$

falls der Grenzwert existiert – die Ableitung der Schnittkurve $t \mapsto f(x + tv)$ in 0. Für $v = e_j$ heißt sie *partielle Ableitung* $\partial f / \partial x_j\,(x)$: Nur die j-te Koordinate bewegt sich.

Beispiel ($f(x, y) = x^2 y$)

y wie eine Konstante behandeln: $\partial f / \partial x = 2xy$; ebenso $\partial f / \partial y = x^2$. In $(1, 2)$ also 4 und 1.

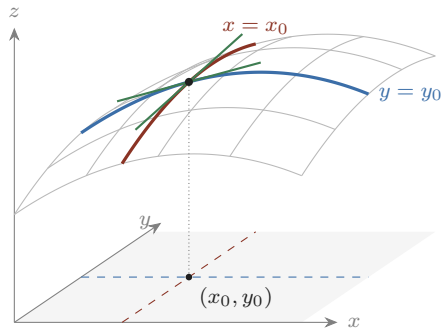
Eine partielle Ableitung ist eine Ableitung in *einer* Variablen – alle Regeln von dort gelten. Sie sieht von f nur eine Gerade durch x.

Partielle Ableitung: die Steigung einer Schnittkurve

Den Graphen anschneiden

Hält man $y = y_0$ fest, schneidet man den Graphen von f längs einer Kurve (blau). Ihre Steigung in x_0 ist $\partial f/\partial x\,(x_0, y_0)$. Hält man $x = x_0$ fest, entsteht die rote Kurve, mit der Steigung $\partial f/\partial y\,(x_0, y_0)$.

Die grünen Tangenten spannen die Tangentialebene auf – wenn es sie gibt. Zwei Richtungen, zwei Zahlen: Was zwischen den Richtungen geschieht, sehen die partiellen Ableitungen nicht.



Satz (Ableitung und partielle Ableitungen)

Sei $f : \mathbb{R}^n \to \mathbb{R}^m$ und $x \in \mathbb{R}^n$.

(a) Ist f in x differenzierbar, so existiert jede Richtungsableitung, und $\partial_v f(x) = Df(x)\, v$. Die j-te Spalte der Jacobi-Matrix ist die partielle Ableitung: $J_f(x) = \left(\partial f_i / \partial x_j\,(x)\right)_{i,j}$.

(b) Existieren die partiellen Ableitungen in einer Umgebung von x und sind sie in x stetig, so ist f in x differenzierbar.

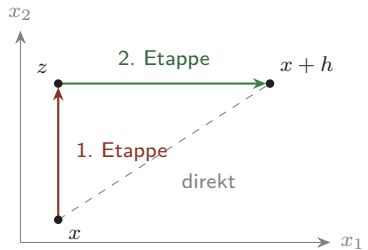
Beweis von (a), mit o. Nach Definition ist $f(x+h) - f(x) - Df(x)\,h = o(h)$ längs $\mathcal{N}(0)$. Setzt man $h = tv$ ein – für $t \to 0$ geht $tv \to 0$ –, bleibt

$$f(x+tv) - f(x) - t\,Df(x)\,v = o(tv) = o(t),$$

denn $\|tv\| = |t|\,\|v\|$. Geteilt durch t: $\frac{f(x+tv)-f(x)}{t} \to Df(x)\,v$. □

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.4: dieser Beweis in Lean, Schritt für Schritt

Beweis von (b): in zwei Etappen von x nach $x + h$



Man geht in zwei Etappen über den Zwischenpunkt $z = (x_1,\ x_2 + h_2)$:

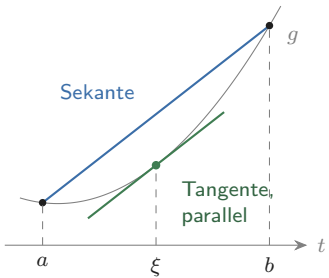
1. erst nur die zweite Koordinate: $x \to z$,
2. dann nur die erste: $z \to x + h$.

Der Zuwachs ist die Summe der Zuwächse beider Etappen, denn $f(z)$ kommt einmal mit $-$ und einmal mit $+$ vor und hebt sich weg:

$$f(x+h) - f(x) = \underbrace{\big[f(x+h) - f(z)\big]}_{\text{2. Etappe}} + \underbrace{\big[f(z) - f(x)\big]}_{\text{1. Etappe}}.$$

Auf jeder Etappe ändert sich nur *eine* Koordinate: Jede Klammer ist die Differenz einer Funktion von *einer* Variablen – dafür gilt der Mittelwertsatz.

Der Mittelwertsatz in einer Variablen



Satz (Mittelwertsatz)

Ist g auf $[a, b]$ stetig und auf (a, b) differenzierbar, so gibt es ein $\xi \in (a, b)$ mit

$$g(b) - g(a) = g'(\xi)\,(b - a).$$

Anschaulich: Irgendwo ist die Tangente parallel zur Sekante.

Wozu hier: Der Zuwachs ist „Steigung an einer Zwischenstelle mal Länge“ – exakt, nicht nur näherungsweise. Für die Klammer $f(x_1 + h_1, x_2 + h_2) - f(x_1, x_2 + h_2)$ setzt man $g(t) = f(x_1 + t,\ x_2 + h_2)$ auf $[0, h_1]$. Dann ist $g'(t) = \partial_1 f(x_1 + t,\ x_2 + h_2)$, und der Satz liefert einen Punkt ξ auf der Strecke mit $g(h_1) - g(0) = \partial_1 f(\xi)\, h_1$.

Beweis von (b): eine Koordinate nach der anderen

Für $n = 2$ und reellwertiges f; sonst je Komponente und je Koordinate ebenso. Sei $h = (h_1, h_2)$ klein.

1. **Zerlegen** in die zwei Etappen von eben, mit $z = (x_1, x_2 + h_2)$:

$$f(x+h) - f(x) = \big[f(x_1+h_1, x_2+h_2) - f(x_1, x_2+h_2)\big] + \big[f(x_1, x_2+h_2) - f(x_1, x_2)\big].$$

2. **Mittelwertsatz** in einer Variablen, je Klammer: Es gibt einen Punkt ξ auf der Strecke von z nach $x + h$ und einen Punkt η auf der Strecke von x nach z mit

$$f(x + h) - f(x) = \partial_1 f(\xi)\, h_1 + \partial_2 f(\eta)\, h_2.$$

Das ist schon fast Jh mit $J = \big(\partial_1 f(x),\ \partial_2 f(x)\big)$ – nur steht $\partial_i f$ an den Zwischenstellen ξ, η statt in x. Wie groß der Unterschied ist, schätzt die nächste Folie ab.

Beweis von (b): den Rest abschätzen

Zu zeigen ist: Der Rest $r(h) = f(x+h) - f(x) - Jh$ ist $o(h)$, mit $J = \big(\partial_1 f(x),\ \partial_2 f(x)\big)$.

1. **Rest bilden.** Wegen $Jh = \partial_1 f(x)\, h_1 + \partial_2 f(x)\, h_2$ und Schritt 2 ist

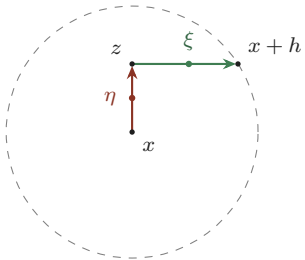
$$r(h) = \big[\partial_1 f(\xi) - \partial_1 f(x)\big]\, h_1 + \big[\partial_2 f(\eta) - \partial_2 f(x)\big]\, h_2.$$

2. **Beträge.** Jede Koordinate ist höchstens $\|h\|$, also

$$|r(h)| \le \Big(\underbrace{|\partial_1 f(\xi) - \partial_1 f(x)| + |\partial_2 f(\eta) - \partial_2 f(x)|}_{\text{muss klein werden}} \Big)\, \|h\|.$$

Die Klammer vergleicht die partiellen Ableitungen an den Zwischenstellen ξ, η mit denen in x. Dass sie für kleine h klein ist, ist genau die Stetigkeit – nächste Folie.

Beweis von (b): hier wird die Stetigkeit gebraucht



Kugel um x, Radius $\|h\|$

3. **Die Klammer klein machen.** Sei $c > 0$. Weil $\partial_1 f, \partial_2 f$ in x stetig sind, gibt es ein $\delta > 0$ mit $|\partial_i f(w) - \partial_i f(x)| < c/2$ für $\|w - x\| < \delta$.
4. Ist $\|h\| < \delta$, so sind ξ und η höchstens $\|h\|$ von x entfernt (Bild), also liegt die Klammer unter $c/2 + c/2 = c$.
5. **Fertig:** Für $\|h\| < \delta$ gilt $|r(h)| \le c\,\|h\|$ – zu jedem c ein δ: Der Rest ist $o(h)$. □

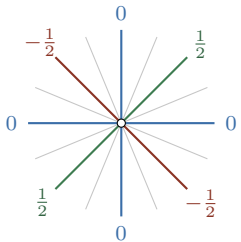
Was genau gebraucht wird

- Die $\partial_i f$ *existieren* um x: für den Mittelwertsatz an den Zwischenstellen ξ, η.
- Die $\partial_i f$ sind in x *stetig*: damit die Klammer gegen 0 geht. Ohne das scheitert genau dieser Schritt – siehe $\frac{xy}{x^2+y^2}$.

Partielle Ableitungen allein reichen nicht

$$f(x,y) = \frac{xy}{x^2+y^2}, \qquad f(0,0) = 0.$$

- Auf beiden Achsen ist $f = 0$: Beide partiellen Ableitungen in 0 existieren und sind 0.
- In Polarkoordinaten ist $f = \cos\varphi \, \sin\varphi = \frac{1}{2}\sin 2\varphi$: auf jedem Strahl konstant, auf der Diagonalen $\frac{1}{2}$. In 0 ist f nicht einmal stetig – erst recht nicht differenzierbar.



f auf den Strahlen: $\frac{1}{2}\sin 2\varphi$

Auch alle Richtungen reichen nicht: $g(x,y) = \frac{x^2 y}{x^2+y^2}$, $g(0,0) = 0$, ist stetig, und $\partial_v g(0) = \frac{v_1^2 v_2}{v_1^2+v_2^2}$ existiert für jedes v – ist aber nicht linear in v. Nach (a) ist g in 0 nicht differenzierbar.

Differenzierbar heißt: *eine* lineare Abbildung für alle Richtungen zugleich, mit einem Fehler $o(h)$.

Vorgerechnet: $f(x,y) = (xy,\ x+y)$

1. **Differenz.** Mit $h = (h_1, h_2)$:
$$f(x+h_1, y+h_2) - f(x,y) = \begin{pmatrix} y\,h_1 + x\,h_2 + h_1 h_2 \\ h_1 + h_2 \end{pmatrix}.$$
2. **Linearer Teil und Rest.**
$$\begin{pmatrix} y\,h_1 + x\,h_2 + h_1 h_2 \\ h_1 + h_2 \end{pmatrix} = \underbrace{\begin{pmatrix} y & x \\ 1 & 1 \end{pmatrix}\begin{pmatrix} h_1 \\ h_2 \end{pmatrix}}_{\text{linear in } h} + \underbrace{\begin{pmatrix} h_1 h_2 \\ 0 \end{pmatrix}}_{\text{Rest } r(h)}.$$
3. **Der Rest ist $o(h)$.** $\|r(h)\| = |h_1 h_2| \le \frac{1}{2}\|h\|^2 \le c\,\|h\|$, sobald $\|h\| \le 2c$.

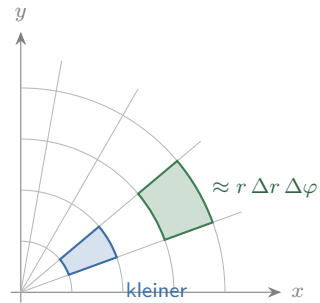
Also ist $J_f(x,y) = \begin{pmatrix} y & x \\ 1 & 1 \end{pmatrix}$. **Probe** mit den partiellen Ableitungen: $\partial_x(xy) = y$, $\partial_y(xy) = x$, $\partial_x(x+y) = \partial_y(x+y) = 1$ – dieselbe Matrix, wie es Teil (a) verlangt. Sie sind stetig: Teil (b) gibt die Differenzierbarkeit auch so.

Polarkoordinaten

$P(r, \varphi) = (r\cos\varphi,\ r\sin\varphi)$, Spalte für Spalte partiell abgeleitet:

$$J_P(r,\varphi) = \begin{pmatrix} \cos\varphi & -r\sin\varphi \\ \sin\varphi & r\cos\varphi \end{pmatrix}.$$

- Spalte 1 ($\partial P/\partial r$): Einheitsvektor nach außen. Spalte 2 ($\partial P/\partial\varphi$): tangential, Länge r.
- $\det J_P = r\cos^2\varphi + r\sin^2\varphi = r$.



Gleiche Δr und $\Delta\varphi$: außen größere Stücke.

Der Flächenfaktor

Ein kleines Rechteck $\Delta r \times \Delta\varphi$ wird ein Stück Kreisring der Fläche $\approx r\,\Delta r\,\Delta\varphi$: $\det J_P$ ist der Faktor, um den P kleine Flächen streckt.

Die Kettenregel: Matrizen multiplizieren

Satz (Kettenregel)

Hat f in x die Ableitung $Df(x)$ und g in $f(x)$ die Ableitung $Dg(f(x))$, so ist

$$D(g \circ f)(x) = Dg(f(x))\, Df(x), \qquad J_{g\circ f}(x) = J_g(f(x)) \cdot J_f(x).$$

Warum, mit o gerechnet: $k = f(x+h) - f(x) = Df(x)\,h + o(h)$ ist höchstens ein festes Vielfaches von $\|h\|$. Also $g(f(x)+k) - g(f(x)) = Dg\,k + o(k) = Dg\,Df\,h + o(h)$: Konstante mal $o(h)$ ist $o(h)$, und $o(k)$ ist $o(h)$, wenn k nicht schneller wächst als h.

Beispiel ($g(u,v) = u^2 + v^2$ nach Polarkoordinaten)

$g(P(r,\varphi)) = r^2$, direkt abgeleitet also $J = (2r,\ 0)$. Mit der Kettenregel:

$$(2r\cos\varphi,\ 2r\sin\varphi)\begin{pmatrix}\cos\varphi & -r\sin\varphi\\ \sin\varphi & r\cos\varphi\end{pmatrix} = (2r\,(\cos^2\varphi + \sin^2\varphi),\ 0) = (2r,\ 0).$$

Gradient und Hesse-Matrix

Für $f : \mathbb{R}^n \to \mathbb{R}$ ist $J_f(x)$ eine Zeile. Als Spalte geschrieben ist sie der *Gradient*: $Df(x)\,h = \langle \nabla f(x), h \rangle$. Die *Hesse-Matrix* $H_f(x)$ ist die Jacobi-Matrix des Gradienten, also die Matrix der zweiten partiellen Ableitungen $\partial^2 f / \partial x_i \partial x_j$.

Beispiel ($f(x,y) = x^2 + xy + y^2 - x - y$)

1. $\nabla f(x,y) = (2x + y - 1,\ x + 2y - 1)$ – die partiellen Ableitungen.
2. $H_f = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, konstant, mit den Eigenwerten 3 und 1 zu den Richtungen $(1,1)$ und $(1,-1)$.
3. $\nabla f = 0$ nur bei $v^* = (\tfrac{1}{3}, \tfrac{1}{3})$. Dort ist f minimal, denn $f(v) = f(v^*) + \tfrac{1}{2}\,(v - v^*)^\top H_f\,(v - v^*)$, und beide Eigenwerte sind positiv.

Allgemein: $f(x) = \tfrac{1}{2}\,x^\top A x - b^\top x$ mit symmetrischem A hat $\nabla f(x) = Ax - b$ und $H_f = A$.

Pause

Danach: Gradientenabstieg

Vorlesung 5

Gradientenabstieg

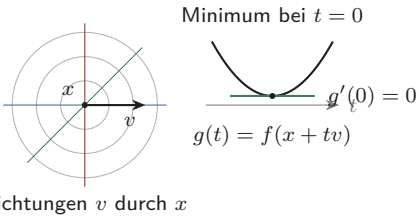
Optimieren: Am lokalen Extremum ist $Df(x) = 0$

Satz (Fermat in mehreren Veränderlichen)

Hat $f : \mathbb{R}^n \to \mathbb{R}$ in x ein lokales Minimum oder Maximum und ist f in x differenzierbar, so ist $Df(x) = 0$, also $\nabla f(x) = 0$.

Beweis. Sei $v \in \mathbb{R}^n$. Die Schnittkurve $g(t) = f(x + tv)$ hat bei $t = 0$ ein lokales Extremum und ist dort differenzierbar mit $g'(0) = Df(x)\,v$ (Teil (a)). Fermat in einer Variablen: $g'(0) = 0$. Das gilt für jedes v, also ist $Df(x) = 0$. □

Beispiel $f(x, y) = x^2 + y^2$: $\nabla f = (2x,\ 2y)$ ist nur im Nullpunkt 0, und dort liegt das Minimum.



Nur *notwendig*: $f(x) = x^3$ hat $f'(0) = 0$, aber kein Extremum. Punkte mit $Df(x) = 0$ heißen *kritisch*.

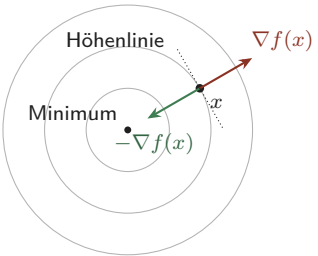
Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: derselbe Beweis in Lean

Der negative Gradient zeigt bergab

Geht man von x aus in Richtung v mit $\|v\| = 1$, ändert sich f zunächst um die Richtungsableitung $\partial_v f(x) = Df(x)\,v = \langle \nabla f(x),\, v\rangle$.

Satz (Steilster Abstieg)

Ist $\nabla f(x) \neq 0$, so ist $\langle \nabla f(x), v\rangle$ unter allen v mit $\|v\| = 1$ am kleinsten für $v = -\nabla f(x)/\|\nabla f(x)\|$, nämlich $-\|\nabla f(x)\|$.



Höhenlinien von f; der Gradient steht senkrecht darauf.

Beweis. Cauchy–Schwarz: $|\langle \nabla f(x), v\rangle| \le \|\nabla f(x)\|\,\|v\| = \|\nabla f(x)\|$, also $\langle \nabla f(x), v\rangle \ge -\|\nabla f(x)\|$. Gleichheit gilt genau, wenn v entgegengesetzt zu $\nabla f(x)$ zeigt. □

Also: $-\nabla f(x)$ ist die Richtung des steilsten Abstiegs, mit der Steigung $-\|\nabla f(x)\|$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: Cauchy–Schwarz, und die Richtung $-g$ erreicht die Grenze

Das Verfahren

Immer ein Stück in die Richtung des steilsten Abstiegs:

Definition (Gradientenabstieg)

Zu f, Schrittweite $t > 0$ und Startwert x_0 setze $\quad x_{k+1} := x_k - t\,\nabla f(x_k).$

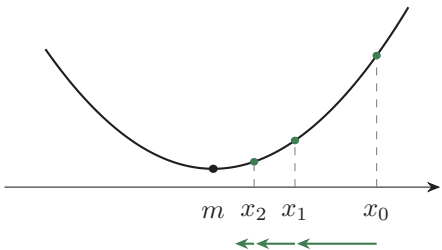
In Lean:

- **Der Gradient** entsteht in Mathlib wie auf Papier: erst die Ableitung, eine lineare Abbildung nach $\mathbb{R}$, dann der Vektor, der sie per Skalarprodukt darstellt. In $\mathbb{R}^n$ gibt es ihn immer.
- **In einer Variablen** über $\mathbb{R}$ ist der Gradient die Ableitung. Ein Schritt ist $x - t\,f'(x)$, die Folge eine Rekursion über n: der Startwert, dann immer wieder ein Schritt.
- **Nicht ausführbar:** Lean erzeugt für diese Definitionen keinen ausführbaren Code. Für das Beweisen ändert das nichts – nur ausrechnen lassen kann man sich nichts.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: Gradient, Schritt und Iteration

Bergab gehen mit fester Schrittlänge

- Man sieht nur die *Steigung* unter den Füßen. Regel: in Richtung des stärksten Gefälles, um t-mal die Steigung.
- Oben steil: große Schritte; nahe am Tal flach: kurze. Das Minimum erreicht man im Allgemeinen nicht exakt, kommt ihm aber geometrisch schnell nahe.
- t zu groß: über das Tal hinaus, drüben höher als vorher – das Verfahren läuft davon.



jeder Schritt halbiert den Abstand zu m

Ein kleines Beispiel: $f(x) = x^2$

$f(x) = x^2$ hat sein Minimum bei 0, und $f'(x) = 2x$. Das Verfahren macht den Schritt

$$x_{k+1} = x_k - t \cdot 2x_k = (1 - 2t)\, x_k.$$

- **Ableitung.** $f'(x) = 2x$, die Potenzregel.
- **Minimum.** 0 ist globales Minimum: $f(x) = x^2 \geq 0 = f(0)$.

In Lean allgemeiner für $q(x) = a\,(x - m)^2 + c$ – das Beispiel ist $a = 1$, $m = c = 0$:

- Mathlibs Regeln bauen die Ableitung Schritt für Schritt auf. Übrig bleibt eine Gleichung zweier Terme, die die Taktik ring nachrechnet.
- Aus der Aussage „q hat in x die Ableitung $2a(x - m)$“ folgt die Formel für die Zahl $q'(x)$, die das Verfahren braucht.
- Für das Minimum genügt der Taktik nlinarith der Hinweis $a\,(x - m)^2 \geq 0$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: Ableitung und Minimum; am Ende der Fall x^2 mit Fehlerformel und Konvergenz

Ein Schritt, exakt ausgerechnet

Wegen $f'(x) = 2x$ ist

$$\begin{aligned} x_{k+1} &= x_k - t\, f'(x_k) \\ &= x_k - t \cdot 2x_k \\ &= (1 - 2t)\, x_k. \end{aligned}$$

Der Wert wird in jedem Schritt mit *demselben* Faktor multipliziert. Halbiert er sich, ist $1 - 2t = \frac{1}{2}$, also $t = \frac{1}{4}$.

Für $q(x) = a\,(x - m)^2 + c$ ist es dasselbe mit dem Fehler $x_k - m$ und dem Faktor $1 - 2at$.

Satz (Fehlerformel und Konvergenz)

Für alle n gilt $\quad x_n = (1-2t)^n\, x_0.\quad$ Ist $|1-2t| < 1$, so konvergiert $x_n \to 0$.

Beweis.

- **Induktionsanfang** $n = 0$: $\quad x_0 = (1-2t)^0\, x_0.$
- **Induktionsschritt:** erst ein Schritt, dann die Induktionsannahme (IA):
  $x_{n+1} = (1-2t)\, x_n \overset{\text{IA}}{=} (1-2t)^{n+1}\, x_0.$
- **Konvergenz.** $\quad |x_n| = |1-2t|^n\, |x_0| \to 0$, denn $r^n \to 0$ für $|r| < 1$. $\square$

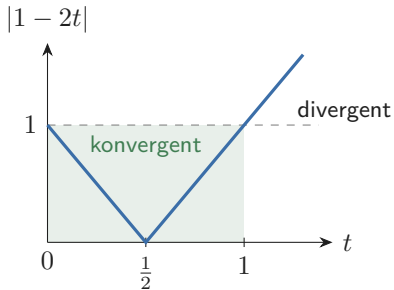
Die Schrittweitenbedingung

Für $f(x) = x^2$:

$$\begin{aligned} |1 - 2t| < 1 &\iff -1 < 1 - 2t < 1 \\ &\iff 0 < 2t < 2 \\ &\iff 0 < t < 1 \end{aligned}$$

(im letzten Schritt durch 2 geteilt)

Das ist genau die Bedingung $0 < t < 2/L$ für L-glatte Funktionen: Hier ist $f'' \equiv 2$, also $L = 2$ und $2/L = 1$.



Drei Dinge in einem Satz

- **Zu große Schritte divergieren.** Für $t > 1$ ist $|1 - 2t| > 1$, der Wert wächst geometrisch.
- **Zu kleine Schritte sind langsam.** Für $t \to 0$ geht $|1 - 2t| \to 1$; die Konvergenz wird beliebig zäh.
- **Es gibt eine beste Schrittweite.** Für $t = 1/2$ ist $1 - 2t = 0$: Das Verfahren trifft das Minimum in einem Schritt.

Zum Nachrechnen: $x_0 = 1$, also $x_n = (1 - 2t)^n$.

t	$1-2t$	x_1	x_2	x_3	x_4	
0,1	0,8	0,8	0,64	0,512	0,4096	langsam
0,25	0,5	0,5	0,25	0,125	0,0625	halbiert
0,5	0	0	0	0	0	ein Schritt
0,75	−0,5	−0,5	0,25	−0,125	0,0625	springt, konvergiert
1	−1	−1	1	−1	1	Randfall: pendelt
1,25	−1,5	−1,5	2,25	−3,375	5,0625	divergiert

Der Konvergenzsatz in Lean

Die ganze Analyse ist in Lean bewiesen, allgemeiner für $q(x) = a\,(x-m)^2 + c$ (das Beispiel ist $a = 1$, $m = c = 0$), in derselben Reihenfolge wie eben:

1. **Ein Schritt.** Den Schritt ausschreiben, q' einsetzen, ausmultiplizieren – die Rechnung von Hand.
2. **Fehlerformel.** Induktion über n wie auf Papier. Den Anfang rechnet Lean nach. Im Induktionsschritt wird eine Iteration entfaltet, dann kommen die Schrittformel und die Induktionsannahme hinein.
3. **Konvergenz.** $r^n \to 0$ für $|r| < 1$ steht in Mathlib. Grenzwertsätze (mal Konstante, plus Konstante) setzen daraus $x_n \to m$ zusammen – kein ε, kein N.
4. **Schrittweite.** $|1 - 2at| < 1 \iff 0 < t < 1/a$: den Betrag auflösen, mit $a > 0$ durchmultiplizieren. Die Ungleichungen mit dem Produkt at sind nicht mehr linear; sie erledigt die Taktik nlinarith.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: im Induktionsbeweis das Ziel nach jeder Taktik ansehen

Gradientenabstieg in zwei Variablen

$f(x,y) = x^2 + xy + y^2 - x - y$, Minimum $v^* = (\frac{1}{3}, \frac{1}{3})$, und $\nabla f(v) = A\,(v - v^*)$ mit der Hesse-Matrix $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$.

1. **Ein Schritt.** $v_{k+1} - v^* = v_k - tA(v_k - v^*) - v^* = (I - tA)\,(v_k - v^*)$: Statt mit der Zahl $1 - 2t$ multipliziert man mit einer Matrix.
2. **In den Eigenrichtungen** wirkt $I - tA$ wie eine Zahl: auf $(1,1)$ als $1 - 3t$, auf $(1,-1)$ als $1 - t$.
3. **Konvergenz von jedem Startwert aus** genau dann, wenn $|1 - 3t| < 1$ und $|1 - t| < 1$, also $0 < t < \frac{2}{3}$.

- Die größte Krümmung, der Eigenwert 3, spielt die Rolle von L: $t < 2/L$. Die kleinste bremst. Am besten ist $t = \frac{2}{1+3} = \frac{1}{2}$, mit dem Faktor $\frac{1}{2}$ je Schritt in beiden Richtungen.
- In Lean: die beiden Eigenrichtungen und ein Schritt, ausgerechnet.

Allgemein: für kleine Schrittweiten sinkt f

Satz

Ist ∇f L-Lipschitz-stetig und $0 < t < 2/L$ (für x^2 ist $L = 2$, also $t < 1$ wie eben), so gilt für das Gradientenverfahren

$$f(x_{k+1}) \;\le\; f(x_k) - t\Big(1 - \frac{Lt}{2}\Big)\,\|\nabla f(x_k)\|^2.$$

Also sinkt $f(x_k)$, und ist f nach unten beschränkt, so gilt $\nabla f(x_k) \to 0$.

Beweis.

1. *Abstiegslemma:* $f(y) \le f(x) + \langle \nabla f(x), y - x\rangle + \frac{L}{2}\,\|y - x\|^2$ – die Parabel liegt über f.
2. $y = x_{k+1} = x_k - t\nabla f(x_k)$ einsetzen: das Skalarprodukt wird $-t\|\nabla f(x_k)\|^2$, der Rest $\frac{L}{2}\,t^2\|\nabla f(x_k)\|^2$.
3. Der Faktor $c = t\,(1 - \frac{Lt}{2})$ ist positiv genau für $t < 2/L$. Summiert man: $c\sum_{k<N} \|\nabla f(x_k)\|^2 \le f(x_0) - \inf f$. Die Reihe konvergiert, also ist $\|\nabla f(x_k)\|$ eine Nullfolge. □

Was in Mathlib fehlt

Der Satz für q ist ein Sonderfall. Die allgemeine Theorie steht nicht in Mathlib:

- das *Abstiegslemma* für L-glatte f:

$$f(x - t\nabla f(x)) \;\le\; f(x) - t\Big(1 - \frac{Lt}{2}\Big)\,\|\nabla f(x)\|^2,$$

- die Rate $O(1/k)$ für konvexe und $O(\rho^k)$ für stark konvexe Zielfunktionen.

Beispiel (Probe am Beispiel x^2)

Für $f(x) = x^2$ ist $L = 2$ und $\nabla f(x) = 2x$. Beide Seiten des Abstiegslemmas ergeben $(1-2t)^2\,x^2$ – für x^2 gilt es mit Gleichheit. Rechts muss man dazu nur $1 - 4t + 4t^2 = (1-2t)^2$ sehen.

Konvex und kritisch: ein globales Minimum

Satz

Ist $f : \mathbb{R} \to \mathbb{R}$ konvex und hat f in c die Ableitung 0, so ist $f(c) \le f(y)$ für alle y.

- Sekante gegen Tangente: Für konvexes f und $x < y$ ist $f'(x) \le \frac{f(y)-f(x)}{y-x} \le f'(y)$. Mit $f'(c) = 0$ ist rechts von c die Sekante ≥ 0, links ≤ 0 – beide Male $f(y) \ge f(c)$.
- In Lean drei Fälle: $y < c$, $y = c$, $y > c$. Die Abschätzung Sekante gegen Tangente steht in Mathlib.
- Vorausgesetzt ist die Aussage „f hat in c die Ableitung 0“, nicht bloß die Zahl $f'(c) = 0$. Die Zahl ist auch an einem Knick 0, als Junk-Wert: $f(x) = \max(x, 2x)$ ist konvex mit $f'(0) = 0$, aber $f(-1) = -1 < 0 = f(0)$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.5: konvex und kritisch, in drei Fällen

Vorlesung 5

Optima unter Nebenbedingungen

Lagrange, klassisch

Gesucht ist ein Extremum nicht auf dem ganzen Raum, sondern nur unter den Punkten mit $f(x) = f(x_0)$.

Satz (Lagrange, klassisch)

Seien f, φ in x_0 streng differenzierbar (etwa: stetig differenzierbar). Hat φ unter der Nebenbedingung $f(x) = f(x_0)$ in x_0 ein lokales Extremum und ist $Df(x_0) \neq 0$, so gibt es ein $\lambda \in \mathbb{R}$ mit

$$D\varphi(x_0) = \lambda\, Df(x_0).$$

- *Streng differenzierbar* in x_0: $f(y) - f(z) - Df(x_0)(y - z) = o(y - z)$ für $y, z \to x_0$ – wie die Ableitung, nur mit zwei beweglichen Punkten.
- Die Voraussetzung $Df(x_0) \neq 0$ (allgemeiner: eine Regularitätsbedingung an die Nebenbedingungen) wird oft weggelassen. Ohne sie stimmt der Satz nicht – Gegenbeispiel: $f(x) = x^2$, $\varphi(x) = x$, $x_0 = 0$.

Ein Beispiel: xy unter $x + y = 1$

Gesucht ist das Maximum von $\varphi(x, y) = xy$ unter $f(x, y) = x + y = 1$.

1. **Gradienten.** $\nabla\varphi = (y, x)$ und $\nabla f = (1, 1) \neq 0$; f und φ sind Polynome, also stetig differenzierbar – die klassische Fassung ist anwendbar.
2. **Lagrange-Bedingung** $\nabla\varphi = \lambda\nabla f$: $\quad y = \lambda, \quad x = \lambda \implies x = y.$
3. **Nebenbedingung** $x + y = 1$: $\quad x = y = \frac{1}{2}$, Wert $\frac{1}{4}$.

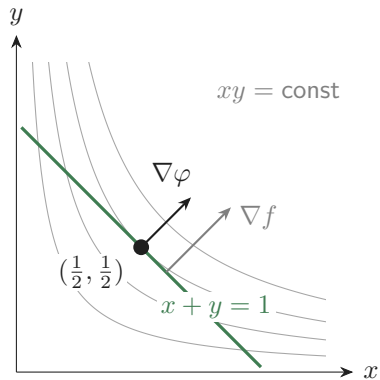
Lagrange liefert nur den *Kandidaten*. Dass das wirklich das Maximum ist, muss man extra zeigen. Hier geht es elementar: Es ist $(x + y)^2 - 4xy = (x - y)^2 \geq 0$, also $xy \leq \frac{1}{4}(x + y)^2 = \frac{1}{4}$.

- In Lean findet die Taktik nlinarith diesen Beweis selbst, mit dem Hinweis $(x - y)^2 \geq 0$.
- Arbeitsteilung: Lagrange verengt die Suche auf endlich viele Punkte, das Optimum bestätigen muss man von Hand.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.6: den Hinweis $(x - y)^2 \geq 0$ weglassen

Wo die Höhenlinie die Straße nur streift

- Eine Straße durchs Gebirge: Die Straße ist die Nebenbedingung $f = \text{const}$, die Höhenlinien sind die Niveaulinien von φ.
- *Kreuzt* die Straße eine Höhenlinie, geht es zur einen Seite bergauf, zur anderen bergab – dort liegt kein Extremum.
- Ein Extremum kann erst liegen, wo sie eine Höhenlinie nur *berührt*: gleiche Tangente, parallele Normalen. Die Normale ist der Gradient, also $\nabla\varphi \parallel \nabla f$.



Lagrange in der Mathlib-Fassung

Satz (Lagrange, Mathlib)

Hat φ unter $f(x) = f(x_0)$ in x_0 ein lokales Extremum und sind f, φ in x_0 streng differenzierbar, so gibt es $(\Lambda, \Lambda_0) \neq (0,0)$ mit $\quad \Lambda \cdot Df(x_0) + \Lambda_0 \cdot D\varphi(x_0) = 0.$

Mathlib formuliert den Satz *projektiv* und kommt damit ohne Regularitätsvoraussetzung aus. Der Zusammenhang mit der klassischen Fassung:

- **Fall** $\Lambda_0 \neq 0$**.** Man darf teilen: $D\varphi(x_0) = -(\Lambda/\Lambda_0)\, Df(x_0)$ – die klassische Form mit $\lambda = -\Lambda/\Lambda_0$.
- **Fall** $\Lambda_0 = 0$**.** Dann ist $\Lambda \neq 0$ und $\Lambda\, Df(x_0) = 0$, also $Df(x_0) = 0$ – genau die Situation, die die klassische Fassung ausschließen muss.
- Ist $Df(x_0) \neq 0$, fällt der zweite Fall weg: Unter denselben Differenzierbarkeitsvoraussetzungen folgt die klassische Fassung aus der projektiven.

Klassisch aus projektiv, in Lean

In Lean ist die klassische Fassung ein Satz, mit genau ihren Voraussetzungen. Der Beweis hat zwei Schritte:

1. Mathlibs projektiver Satz, der Satz der vorigen Folie, liefert $(\Lambda, \Lambda_0) \neq (0, 0)$.
2. Ein eigenes Lemma macht die Fallunterscheidung, reine lineare Algebra: $\Lambda_0 = 0$ führt auf $Df(x_0) = 0$, sonst teilt man durch Λ_0.

Das λ heißt in Lean μ, denn λ ist dort für Funktionen reserviert.

Beispiel (Warum es $Df(x_0) \neq 0$ braucht)

$f(x) = x^2$, $\varphi(x) = x$ auf $\mathbb{R}$, $x_0 = 0$: Die Nebenbedingung $x^2 = 0$ lässt nur $x = 0$ zu, also liegt dort ein Extremum. Aber $D\varphi(0) = 1$ und $Df(0) = 0$ – kein λ mit $1 = \lambda \cdot 0$. Projektiv geht es: $\Lambda = 1$, $\Lambda_0 = 0$.

Live in Lean `code/Vorlesung05.lean` – Abschnitt 4.6: erst das Lemma mit der Fallunterscheidung, dann der Satz

Zusammenfassung

- Landau-Symbole: $f = o(g)$ längs l heißt, zu jedem $c > 0$ ist $\|f\| \leq c\,\|g\|$ schließlich. Kein Teilen; der Filter entscheidet mit; die Summenregel ist Axiom (iii).
- Ableitung: Fehler $= o(y - x_0)$ längs $\mathcal{N}(x_0)$. Die Zahl $f'(x_0)$ ist in Mathlib total, mit Junk-Wert 0.
- Mehrere Veränderliche: Die Ableitung ist die Jacobi-Matrix. Ihre Spalten sind die partiellen Ableitungen; stetige partielle Ableitungen liefern Differenzierbarkeit, partielle Ableitungen allein nicht. Die Kettenregel multipliziert Jacobi-Matrizen.
- Gradientenabstieg: $-\nabla f$ ist die Richtung des steilsten Abstiegs. Auf x^2 ist $x_n = (1 - 2t)^n\, x_0$, Konvergenz für $0 < t < 1$; allgemein sinkt f für $0 < t < 2/L$. In zwei Variablen multipliziert ein Schritt den Fehler mit $I - tA$.
- Lagrange in Mathlib: projektiv; klassisch, sobald $Df(x_0) \neq 0$.

Nächstes Mal: Numerische Integration

- Das Integral in Mathlib – wie die Ableitung total: Ist f nicht integrierbar, ist der Wert 0.
- Quadraturformeln (Mittelpunkt, Trapez, Simpson) und ihr Exaktheitsgrad – vollständig in Lean bewiesen.
- Mehrere Dimensionen: Fubini, der Fluch der Dimension, Monte-Carlo.
- Ein Experiment mit Gleitkommazahlen: Trapez und Simpson in einer Dimension, Gitter gegen Monte-Carlo in zwei.
- Zum Schluss der Schritt zu Differentialgleichungen: Aus $x' = f(t, x)$ wird eine Gleichung mit einem Integral.