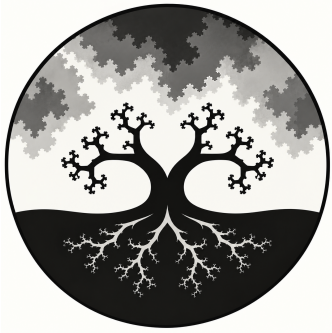


Angewandte Mathematik

Vorlesung 6 von 10

Optimierung

Skript: Abschnitte 4.4–4.6

Ablauf heute

0:00	Rückblick: Ableitung	Vorlesung 5
0:08	Teil 1: Die Taylorformel in mehreren Veränderlichen	Skript 4.4
0:25	Hoch-, Tief- und Sattelpunkte	Skript 4.4
0:52	*Pause*	
1:07	Teil 2: Gradientenabstieg – in einer und in zwei Variablen	Skript 4.5
1:40	Optima unter Nebenbedingungen: Lagrange	Skript 4.6
1:57	Zusammenfassung und Ausblick	
2:02	Lean live: Blatt 6, Teil B anfangen	Übungsblatt 6
2:30	Ende	

Rückblick: Vorlesung 5

- **Landau-Symbole:** $f = o(g)$ längs eines Filters heißt: Zu jedem $c > 0$ ist $\|f\| \le c\,\|g\|$ schließlich – ohne zu teilen. Der Filter entscheidet mit: $x^2 = o(x)$ bei 0, $x = o(x^2)$ bei ∞.
- **Ableitung** als lineare Näherung: Der Fehler der Tangente ist $o(y - x)$. In Mathlib ist die Zahl $f'(x)$ total (Junk-Wert 0). Am lokalen Minimum ist $f' = 0$.
- **Mehrere Veränderliche:** Die Ableitung ist die Jacobi-Matrix, ihre Spalten sind die partiellen Ableitungen, die Kettenregel ist ein Matrixprodukt.
- **Gradient und Hesse-Matrix:** ∇f ist die Jacobi-Zeile, die Hesse-Matrix die Jacobi-Matrix des Gradienten. Für $x^2 + xy + y^2 - x - y$ ist sie $\left(\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right)$, mit den Eigenwerten 3 und 1.

Vorlesung 6

Die Taylorformel in mehreren Veränderlichen

Satz (Taylorformel in mehreren Veränderlichen)

Sei $(h \cdot \nabla) f = \sum_i h_i \, \partial f / \partial x_i$ die Richtungsableitung in Richtung h. Ist f nahe der Strecke von p nach $p + h$ $(k+1)$-mal stetig differenzierbar, so gibt es ein $\tau \in (0,1)$ mit

$$f(p+h) = \sum_{j=0}^{k} \frac{1}{j!} (h \cdot \nabla)^j f(p) + \frac{1}{(k+1)!} (h \cdot \nabla)^{k+1} f(p + \tau h).$$

Bei nur k-mal stetig differenzierbarem f ist der Rest nach Ordnung k ein $o(\|h\|^k)$.

Beweis. $g(t) = f(p + th)$ hat nach der Kettenregel $g^{(j)}(t) = (h \cdot \nabla)^j f(p + th)$. Taylor in einer Variablen mit dem Restglied von Lagrange:
$g(1) = \sum_{j \le k} g^{(j)}(0)/j! + g^{(k+1)}(\tau)/(k+1)!$. □

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: die Kettenregel für die Schnittkurve, Taylor in einer Variablen aus Mathlib

Die ersten Glieder

- $j = 1$: $(h \cdot \nabla) f(p) = \nabla f(p) \cdot h$, die lineare Näherung.
- $j = 2$: $(h \cdot \nabla)^2 f(p) = \sum_{i,j} h_i h_j \, \frac{\partial^2 f}{\partial x_i \partial x_j}(p) = h^\top H_f(p)\, h$.

Bis zur zweiten Ordnung also

$$f(p+h) = f(p) + \nabla f(p) \cdot h + \tfrac{1}{2}\, h^\top H_f(p)\, h + o(\|h\|^2),$$

in zwei Variablen, $h = (h_1, h_2)$, alle Ableitungen in p:

$$f(p+h) = f + f_x h_1 + f_y h_2 + \tfrac{1}{2}(f_{xx} h_1^2 + 2 f_{xy} h_1 h_2 + f_{yy} h_2^2) + o(\|h\|^2).$$

Mit Multiindizes $\alpha = (\alpha_1, \ldots, \alpha_n)$, $|\alpha| = \sum_i \alpha_i$, $\alpha! = \prod_i \alpha_i!$, $h^\alpha = \prod_i h_i^{\alpha_i}$:

$$\sum_{j=0}^{k} \frac{1}{j!} (h \cdot \nabla)^j f(p) = \sum_{|\alpha| \le k} \frac{\partial^\alpha f(p)}{\alpha!}\, h^\alpha.$$

Das braucht, dass die partiellen Ableitungen vertauschen – der Satz von Schwarz, für stetige zweite Ableitungen.

Vorgerechnet: Taylor in zwei Variablen

$f(x,y) = e^x \cos y$ **in** $p = 0$**:** $f(0) = 1$, $\nabla f(0) = (1,0)$, $H_f(0) = \left(\begin{smallmatrix} 1 & 0 \\ 0 & -1 \end{smallmatrix}\right)$, also

$$T_2(h) = 1 + h_1 + \tfrac{1}{2}\,(h_1^2 - h_2^2).$$

bei $h = (0{,}1;\ 0{,}2)$	Wert	Fehler
f	1,083141	
T_2	1,085000	$1{,}9 \cdot 10^{-3}$
$T_3 = T_2 + \frac{1}{6}\,(h_1^3 - 3h_1h_2^2)$	1,083167	$2{,}6 \cdot 10^{-5}$

Ein Polynom vom Grad k ist gleich seinem Taylorpolynom k-ter Ordnung. Für $f(x,y) = x^3 + y^3 - 3xy$ in $(1,1)$ ist der Gradient 0, die Hesse-Matrix $\left(\begin{smallmatrix} 6 & -3 \\ -3 & 6 \end{smallmatrix}\right)$, und exakt

$$f(1+h_1, 1+h_2) = -1 + \tfrac{1}{2}\,(6h_1^2 - 6h_1h_2 + 6h_2^2) + (h_1^3 + h_2^3).$$

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: die Entwicklung von $x^3 + y^3 - 3xy$, mit `ring`

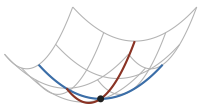
Vorlesung 6

Hoch-, Tief- und Sattelpunkte

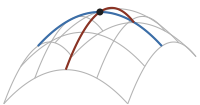
Tief-, Hoch- und Sattelpunkte

Definition (Lokale Extrema, kritische Punkte, Sattelpunkte)

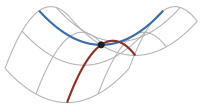
Sei $f : \mathbb{R}^n \to \mathbb{R}$. f hat in p ein *lokales Minimum* (einen *Tiefpunkt*), wenn schließlich längs $\mathcal{N}(p)$ gilt: $f(p) \leq f(x)$, also auf einer Kugel um p; *strikt*, wenn $f(p) < f(x)$ für $x \neq p$ nahe p. Ein *lokales Maximum* (*Hochpunkt*) ist dasselbe mit $\geq$. Ein Punkt mit $\nabla f(p) = 0$ heißt *kritisch*; ein kritischer Punkt ohne lokales Extremum heißt *Sattelpunkt*.



Tiefpunkt: $x^2 + y^2$



Hochpunkt: $-x^2 - y^2$



Sattelpunkt: $x^2 - y^2$

Blau die Schnittkurve längs der x-Achse, rot die längs der y-Achse. Beim Sattel hat die eine in 0 ein Minimum, die andere ein Maximum: Jede Kugel um 0 enthält Punkte mit $f > 0$ und mit $f < 0$ – wie ein Pass im Gebirge.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: die Definition, wie Mathlibs IsLocalMin, und die drei Grundformen

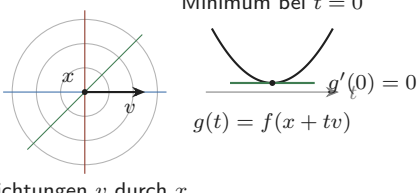
Optimieren: Am lokalen Extremum ist $Df(x) = 0$

Satz (Fermat in mehreren Veränderlichen)

Hat $f : \mathbb{R}^n \to \mathbb{R}$ in x ein lokales Minimum oder Maximum und ist f in x differenzierbar, so ist $Df(x) = 0$, also $\nabla f(x) = 0$.

Beweis. Sei $v \in \mathbb{R}^n$. Die Schnittkurve $g(t) = f(x + tv)$ hat bei $t = 0$ ein lokales Extremum und ist dort differenzierbar mit $g'(0) = Df(x)\,v$ (Teil (a)). Fermat in einer Variablen: $g'(0) = 0$. Das gilt für jedes v, also ist $Df(x) = 0$. □

Beispiel $f(x, y) = x^2 + y^2$: $\nabla f = (2x,\ 2y)$ ist nur im Nullpunkt 0, und dort liegt das Minimum.



Nur *notwendig*: $f(x) = x^3$ hat $f'(0) = 0$, aber kein Extremum; in der Ebene ebenso der Sattel $x^2 - y^2$ im Nullpunkt.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: derselbe Beweis in Lean

Die Hesse-Matrix entscheidet

In einem kritischen Punkt p fällt in der Taylorformel zweiter Ordnung der lineare Term weg:

$$f(p+h) - f(p) = \tfrac{1}{2}\, Q(h) + o(\|h\|^2), \qquad Q(h) = h^\top H_f(p)\, h.$$

- Nahe p sieht f also aus wie die *quadratische Form* Q – wie eine der drei Grundformen, wenn Q nicht entartet ist.
- In einer Eigenrichtung v zum Eigenwert λ ist $Q(tv) = \lambda\, t^2 \|v\|^2$: Das Vorzeichen von λ sagt, ob es dort bergauf oder bergab geht.
- Bergauf in allen Richtungen: Tiefpunkt. Bergab in allen: Hochpunkt. Beides: Sattel.

Das Hesse-Kriterium

Satz (Hesse-Kriterium)

Sei f nahe p zweimal stetig differenzierbar, $\nabla f(p) = 0$ und $H = H_f(p)$.

(a) H *positiv definit* ($h^\top H h > 0$ für $h \neq 0$): striktes lokales Minimum.

(b) H *negativ definit* ($h^\top H h < 0$ für $h \neq 0$): striktes lokales Maximum.

(c) H *indefinit* ($h^\top H h$ nimmt beide Vorzeichen an): Sattelpunkt.

Beweis. (a) Auf der Einheitssphäre, die kompakt ist, hat $Q(h) = h^\top H h$ ein Minimum $m > 0$; also ist $Q(h) \geq m \, \|h\|^2$. Mit $c = m/4$ im o ist schließlich

$$f(p+h) - f(p) \;\geq\; \tfrac{m}{2}\,\|h\|^2 - \tfrac{m}{4}\,\|h\|^2 \;=\; \tfrac{m}{4}\,\|h\|^2 \;>\; 0 \qquad (h \neq 0).$$

(b) ist (a) für $-f$. (c) Ist $Q(v) < 0$, so ist $f(p+tv) - f(p) = \tfrac{1}{2}\,t^2 Q(v) + o(t^2) < 0$ für kleine $t \neq 0$; mit $Q(w) > 0$ ebenso $f(p+tw) > f(p)$. □

Semidefinit ($Q \geq 0$, aber $Q(h) = 0$ für ein $h \neq 0$): keine Entscheidung. $x^2 + y^4$, $x^2 - y^4$ und $x^2 + y^3$ haben in 0 alle die Hesse-Matrix $\left(\begin{smallmatrix} 2 & 0 \\ 0 & 0 \end{smallmatrix}\right)$ – ein Minimum, zwei Sattelpunkte.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: Teil (a) mit KleinO und c = m/4

In zwei Dimensionen: Determinante und Spur

$H = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$, $Q(h,k) = ah^2 + 2b\,hk + ck^2$. Quadratisch ergänzt, für $a \neq 0$:
$a\,Q(h,k) = (ah + bk)^2 + (ac - b^2)\,k^2$.

$\det H > 0$, $a > 0$	positiv definit	Tiefpunkt
$\det H > 0$, $a < 0$	negativ definit	Hochpunkt
$\det H < 0$	indefinit	Sattelpunkt
$\det H = 0$	semidefinit	offen

In Eigenwerten: $\det H = \lambda_1\lambda_2$ und $\operatorname{Spur} H = a + c = \lambda_1 + \lambda_2$. Bei $\det H > 0$ haben beide dasselbe Vorzeichen, das von a; bei $\det H < 0$ verschiedene.

Die Schranke für (a), hier ohne Kompaktheit:

$$(a + c)\,Q(h,k) - (ac - b^2)\,(h^2 + k^2) = (ah + bk)^2 + (bh + ck)^2 \;\geq\; 0,$$

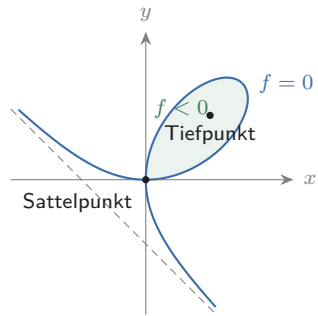
also $Q(h,k) \geq m\,(h^2 + k^2)$ mit $m = \det H / \operatorname{Spur} H$.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: die Identität mit ring, die Schranke und Mathlibs positiv definite Matrix

Vorgerechnet: $f(x,y) = x^3 + y^3 - 3xy$

$$\nabla f = (3x^2 - 3y,\ 3y^2 - 3x), \qquad H_f = \begin{pmatrix} 6x & -3 \\ -3 & 6y \end{pmatrix}.$$

1. **Kritisch:** $y = x^2$, $x = y^2$, also $x = x^4$: $(0,0)$ und $(1,1)$.
2. $(1,1)$**:** $\det H = 36 - 9 = 27 > 0$, $a = 6 > 0$: Tiefpunkt, $f(1,1) = -1$.
3. $(0,0)$**:** $\det H = -9 < 0$: Sattelpunkt. In den Eigenrichtungen $(1,1)$ und $(1,-1)$ ist $f(t,t) = t^2(2t-3) < 0$ für kleine $t \neq 0$, aber $f(t,-t) = 3t^2 > 0$.
4. **Global** kein Minimum: $f(x,0) = x^3$ fällt unter jede Schranke.



Die Höhenlinie $f = 0$ kreuzt sich im Sattelpunkt.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: der Tiefpunkt mit dem Hesse-Kriterium, der Sattel mit den Punkten (t,t) und $(t,-t)$

Höhere Dimensionen

- **Spektralsatz:** H ist symmetrisch, hat also eine Orthonormalbasis aus Eigenvektoren v_i mit reellen Eigenwerten $\lambda_1 \le \cdots \le \lambda_n$, und $h^\top H h = \sum_i \lambda_i \langle h, v_i\rangle^2 \ge \lambda_1 \|h\|^2$.
- Positiv definit: alle $\lambda_i > 0$ (das m im Beweis ist λ_1); negativ definit: alle $\lambda_i < 0$; indefinit: Eigenwerte beider Vorzeichen.
- **Morse-Index:** die Zahl der negativen Eigenwerte, also der unabhängigen Richtungen bergab. Index 0 ist ein Tiefpunkt, Index n ein Hochpunkt, dazwischen liegen Sattelpunkte.
- **Kriterium von Sylvester:** positiv definit genau dann, wenn alle führenden Hauptminoren $\det(h_{ij})_{i,j\le k}$ positiv sind; für $n = 2$: $a > 0$ und $\det H > 0$.

In hohen Dimensionen ist fast alles Sattel

Ein Tiefpunkt braucht n positive Eigenwerte. Wären die Vorzeichen Münzwürfe, wäre nur jeder 2^n-te kritische Punkt einer. Bei neuronalen Netzen mit Millionen von Parametern spricht vieles dafür, dass kritische Punkte mit hohem Verlust fast immer Sattelpunkte sind.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.4: positiv definite Matrizen und Eigenwerte in Mathlib

Pause

Danach: Gradientenabstieg und Lagrange

Vorlesung 6

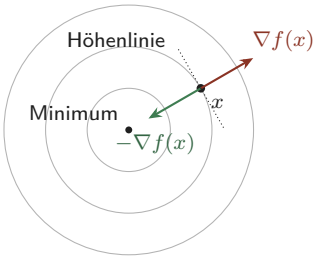
Gradientenabstieg

Der negative Gradient zeigt bergab

Geht man von x aus in Richtung v mit $\|v\| = 1$, ändert sich f zunächst um die Richtungsableitung $\partial_v f(x) = Df(x)\,v = \langle \nabla f(x),\, v\rangle$.

Satz (Steilster Abstieg)

Ist $\nabla f(x) \neq 0$, so ist $\langle \nabla f(x), v\rangle$ unter allen v mit $\|v\| = 1$ am kleinsten für $v = -\nabla f(x)/\|\nabla f(x)\|$, nämlich $-\|\nabla f(x)\|$.



Höhenlinien von f; der Gradient steht senkrecht darauf.

Beweis. Cauchy–Schwarz: $|\langle \nabla f(x), v\rangle| \le \|\nabla f(x)\|\,\|v\| = \|\nabla f(x)\|$, also $\langle \nabla f(x), v\rangle \ge -\|\nabla f(x)\|$. Gleichheit gilt genau, wenn v entgegengesetzt zu $\nabla f(x)$ zeigt. □

Also: $-\nabla f(x)$ ist die Richtung des steilsten Abstiegs, mit der Steigung $-\|\nabla f(x)\|$.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.5: Cauchy–Schwarz, und die Richtung $-g$ erreicht die Grenze

Das Verfahren

Immer ein Stück in die Richtung des steilsten Abstiegs:

Definition (Gradientenabstieg)

Zu f, Schrittweite $t > 0$ und Startwert x_0 setze $\quad x_{k+1} := x_k - t\,\nabla f(x_k).$

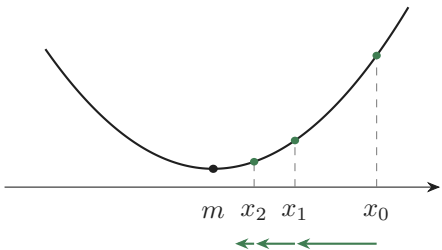
In Lean:

- **Der Gradient** entsteht in Mathlib wie auf Papier: erst die Ableitung, eine lineare Abbildung nach $\mathbb{R}$, dann der Vektor, der sie per Skalarprodukt darstellt. In $\mathbb{R}^n$ gibt es ihn immer.
- **In einer Variablen** über $\mathbb{R}$ ist der Gradient die Ableitung. Ein Schritt ist $x - t\,f'(x)$, die Folge eine Rekursion über n: der Startwert, dann immer wieder ein Schritt.
- **Nicht ausführbar:** Lean erzeugt für diese Definitionen keinen ausführbaren Code. Für das Beweisen ändert das nichts – nur ausrechnen lassen kann man sich nichts.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.5: Gradient, Schritt und Iteration

Bergab gehen mit fester Schrittlänge

- Man sieht nur die *Steigung* unter den Füßen. Regel: in Richtung des stärksten Gefälles, um t-mal die Steigung.
- Oben steil: große Schritte; nahe am Tal flach: kurze. Das Minimum erreicht man im Allgemeinen nicht exakt, kommt ihm aber geometrisch schnell nahe.
- t zu groß: über das Tal hinaus, drüben höher als vorher – das Verfahren läuft davon.



jeder Schritt halbiert den Abstand zu m

Ein kleines Beispiel: $f(x) = x^2$

$f(x) = x^2$ hat sein Minimum bei 0, und $f'(x) = 2x$. Das Verfahren macht den Schritt

$$x_{k+1} = x_k - t \cdot 2x_k = (1 - 2t)\, x_k.$$

- **Ableitung.** $f'(x) = 2x$, die Potenzregel.
- **Minimum.** 0 ist globales Minimum: $f(x) = x^2 \geq 0 = f(0)$.

In Lean allgemeiner für $q(x) = a\,(x - m)^2 + c$ – das Beispiel ist $a = 1$, $m = c = 0$:

- Mathlibs Regeln bauen die Ableitung Schritt für Schritt auf. Übrig bleibt eine Gleichung zweier Terme, die die Taktik ring nachrechnet.
- Aus der Aussage „q hat in x die Ableitung $2a(x - m)$“ folgt die Formel für die Zahl $q'(x)$, die das Verfahren braucht.
- Für das Minimum genügt der Taktik nlinarith der Hinweis $a\,(x - m)^2 \geq 0$.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.5: Ableitung und Minimum; am Ende der Fall x^2 mit Fehlerformel und Konvergenz

Ein Schritt, exakt ausgerechnet

Wegen $f'(x) = 2x$ ist

$$\begin{aligned} x_{k+1} &= x_k - t\, f'(x_k) \\ &= x_k - t \cdot 2x_k \\ &= (1 - 2t)\, x_k. \end{aligned}$$

Der Wert wird in jedem Schritt mit *demselben* Faktor multipliziert. Halbiert er sich, ist $1 - 2t = \frac{1}{2}$, also $t = \frac{1}{4}$.

Für $q(x) = a\,(x - m)^2 + c$ ist es dasselbe mit dem Fehler $x_k - m$ und dem Faktor $1 - 2at$.

Satz (Fehlerformel und Konvergenz)

Für alle n gilt $\quad x_n = (1-2t)^n\, x_0.\quad$ Ist $|1-2t| < 1$, so konvergiert $x_n \to 0$.

Beweis.

- **Induktionsanfang** $n = 0$: $\quad x_0 = (1-2t)^0\, x_0.$
- **Induktionsschritt:** erst ein Schritt, dann die Induktionsannahme (IA):
  $x_{n+1} = (1-2t)\, x_n \overset{\text{IA}}{=} (1-2t)^{n+1}\, x_0.$
- **Konvergenz.** $\quad |x_n| = |1-2t|^n\, |x_0| \to 0$, denn $r^n \to 0$ für $|r| < 1$. $\square$

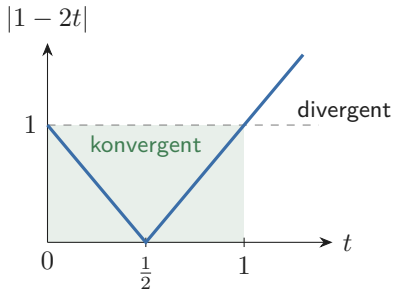
Die Schrittweitenbedingung

Für $f(x) = x^2$:

$$\begin{aligned} |1 - 2t| < 1 &\iff -1 < 1 - 2t < 1 \\ &\iff 0 < 2t < 2 \\ &\iff 0 < t < 1 \end{aligned}$$

(im letzten Schritt durch 2 geteilt)

Das ist genau die Bedingung $0 < t < 2/L$ für L-glatte Funktionen: Hier ist $f'' \equiv 2$, also $L = 2$ und $2/L = 1$.



Drei Dinge in einem Satz

- **Zu große Schritte divergieren.** Für $t > 1$ ist $|1 - 2t| > 1$, der Wert wächst geometrisch.
- **Zu kleine Schritte sind langsam.** Für $t \to 0$ geht $|1 - 2t| \to 1$; die Konvergenz wird beliebig zäh.
- **Es gibt eine beste Schrittweite.** Für $t = 1/2$ ist $1 - 2t = 0$: Das Verfahren trifft das Minimum in einem Schritt.

Zum Nachrechnen: $x_0 = 1$, also $x_n = (1 - 2t)^n$.

t	$1-2t$	x_1	x_2	x_3	x_4	
0,1	0,8	0,8	0,64	0,512	0,4096	langsam
0,25	0,5	0,5	0,25	0,125	0,0625	halbiert
0,5	0	0	0	0	0	ein Schritt
0,75	−0,5	−0,5	0,25	−0,125	0,0625	springt, konvergiert
1	−1	−1	1	−1	1	Randfall: pendelt
1,25	−1,5	−1,5	2,25	−3,375	5,0625	divergiert

Der Konvergenzsatz in Lean

Die ganze Analyse ist in Lean bewiesen, allgemeiner für $q(x) = a\,(x-m)^2 + c$ (das Beispiel ist $a = 1$, $m = c = 0$), in derselben Reihenfolge wie eben:

1. **Ein Schritt.** Den Schritt ausschreiben, q' einsetzen, ausmultiplizieren – die Rechnung von Hand.
2. **Fehlerformel.** Induktion über n wie auf Papier. Den Anfang rechnet Lean nach. Im Induktionsschritt wird eine Iteration entfaltet, dann kommen die Schrittformel und die Induktionsannahme hinein.
3. **Konvergenz.** $r^n \to 0$ für $|r| < 1$ steht in Mathlib. Grenzwertsätze (mal Konstante, plus Konstante) setzen daraus $x_n \to m$ zusammen – kein ε, kein N.
4. **Schrittweite.** $|1 - 2at| < 1 \iff 0 < t < 1/a$: den Betrag auflösen, mit $a > 0$ durchmultiplizieren. Die Ungleichungen mit dem Produkt at sind nicht mehr linear; sie erledigt die Taktik nlinarith.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.5: im Induktionsbeweis das Ziel nach jeder Taktik ansehen

Gradientenabstieg in zwei Variablen

$f(x,y) = x^2 + xy + y^2 - x - y$, Minimum $v^* = (\frac{1}{3}, \frac{1}{3})$, und $\nabla f(v) = A\,(v - v^*)$ mit der Hesse-Matrix $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$.

1. **Ein Schritt.** $v_{k+1} - v^* = v_k - tA(v_k - v^*) - v^* = (I - tA)\,(v_k - v^*)$: Statt mit der Zahl $1 - 2t$ multipliziert man mit einer Matrix.
2. **In den Eigenrichtungen** wirkt $I - tA$ wie eine Zahl: auf $(1,1)$ als $1 - 3t$, auf $(1,-1)$ als $1 - t$.
3. **Konvergenz von jedem Startwert aus** genau dann, wenn $|1 - 3t| < 1$ und $|1 - t| < 1$, also $0 < t < \frac{2}{3}$.

- Die größte Krümmung, der Eigenwert 3, spielt die Rolle von L: $t < 2/L$. Die kleinste bremst. Am besten ist $t = \frac{2}{1+3} = \frac{1}{2}$, mit dem Faktor $\frac{1}{2}$ je Schritt in beiden Richtungen.
- In Lean: die beiden Eigenrichtungen und ein Schritt, ausgerechnet.

Allgemein: für kleine Schrittweiten sinkt f

Satz

Ist ∇f L-Lipschitz-stetig und $0 < t < 2/L$ (für x^2 ist $L = 2$, also $t < 1$ wie eben), so gilt für das Gradientenverfahren

$$f(x_{k+1}) \;\leq\; f(x_k) - t\Big(1 - \frac{Lt}{2}\Big)\,\|\nabla f(x_k)\|^2.$$

Also sinkt $f(x_k)$, und ist f nach unten beschränkt, so gilt $\nabla f(x_k) \to 0$.

Beweis.

1. *Abstiegslemma:* $f(y) \leq f(x) + \langle \nabla f(x), y - x\rangle + \frac{L}{2}\,\|y - x\|^2$ – die Parabel liegt über f.
2. $y = x_{k+1} = x_k - t\nabla f(x_k)$ einsetzen: das Skalarprodukt wird $-t\|\nabla f(x_k)\|^2$, der Rest $\frac{L}{2}\,t^2\|\nabla f(x_k)\|^2$.
3. Der Faktor $c = t\,(1 - \frac{Lt}{2})$ ist positiv genau für $t < 2/L$. Summiert man: $c\sum_{k<N} \|\nabla f(x_k)\|^2 \leq f(x_0) - \inf f$. Die Reihe konvergiert, also ist $\|\nabla f(x_k)\|$ eine Nullfolge. □

Was in Mathlib fehlt

Der Satz für q ist ein Sonderfall. Die allgemeine Theorie steht nicht in Mathlib:

- das *Abstiegslemma* für L-glatte f:

$$f(x - t\nabla f(x)) \;\le\; f(x) - t\Big(1 - \frac{Lt}{2}\Big)\,\|\nabla f(x)\|^2,$$

- die Rate $O(1/k)$ für konvexe und $O(\rho^k)$ für stark konvexe Zielfunktionen.

Beispiel (Probe am Beispiel x^2)

Für $f(x) = x^2$ ist $L = 2$ und $\nabla f(x) = 2x$. Beide Seiten des Abstiegslemmas ergeben $(1-2t)^2\,x^2$ – für x^2 gilt es mit Gleichheit. Rechts muss man dazu nur $1 - 4t + 4t^2 = (1-2t)^2$ sehen.

Konvex und kritisch: ein globales Minimum

Satz

Ist $f : \mathbb{R} \to \mathbb{R}$ konvex und hat f in c die Ableitung 0, so ist $f(c) \le f(y)$ für alle y.

- Sekante gegen Tangente: Für konvexes f und $x < y$ ist $f'(x) \le \frac{f(y)-f(x)}{y-x} \le f'(y)$. Mit $f'(c) = 0$ ist rechts von c die Sekante ≥ 0, links ≤ 0 – beide Male $f(y) \ge f(c)$.
- In Lean drei Fälle: $y < c$, $y = c$, $y > c$. Die Abschätzung Sekante gegen Tangente steht in Mathlib.
- Vorausgesetzt ist die Aussage „f hat in c die Ableitung 0“, nicht bloß die Zahl $f'(c) = 0$. Die Zahl ist auch an einem Knick 0, als Junk-Wert: $f(x) = \max(x, 2x)$ ist konvex mit $f'(0) = 0$, aber $f(-1) = -1 < 0 = f(0)$.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.5: konvex und kritisch, in drei Fällen

Vorlesung 6

Optima unter Nebenbedingungen

Lagrange, klassisch

Gesucht ist ein Extremum nicht auf dem ganzen Raum, sondern nur unter den Punkten mit $f(x) = f(x_0)$.

Satz (Lagrange, klassisch)

Seien f, φ in x_0 streng differenzierbar (etwa: stetig differenzierbar). Hat φ unter der Nebenbedingung $f(x) = f(x_0)$ in x_0 ein lokales Extremum und ist $Df(x_0) \neq 0$, so gibt es ein $\lambda \in \mathbb{R}$ mit

$$D\varphi(x_0) = \lambda\, Df(x_0).$$

- *Streng differenzierbar* in x_0: $f(y) - f(z) - Df(x_0)(y - z) = o(y - z)$ für $y, z \to x_0$ – wie die Ableitung, nur mit zwei beweglichen Punkten.
- Die Voraussetzung $Df(x_0) \neq 0$ (allgemeiner: eine Regularitätsbedingung an die Nebenbedingungen) wird oft weggelassen. Ohne sie stimmt der Satz nicht – Gegenbeispiel: $f(x) = x^2$, $\varphi(x) = x$, $x_0 = 0$.

Ein Beispiel: xy unter $x + y = 1$

Gesucht ist das Maximum von $\varphi(x, y) = xy$ unter $f(x, y) = x + y = 1$.

1. **Gradienten.** $\nabla\varphi = (y, x)$ und $\nabla f = (1, 1) \neq 0$; f und φ sind Polynome, also stetig differenzierbar – die klassische Fassung ist anwendbar.
2. **Lagrange-Bedingung** $\nabla\varphi = \lambda\nabla f$: $\quad y = \lambda, \quad x = \lambda \implies x = y.$
3. **Nebenbedingung** $x + y = 1$: $\quad x = y = \frac{1}{2}$, Wert $\frac{1}{4}$.

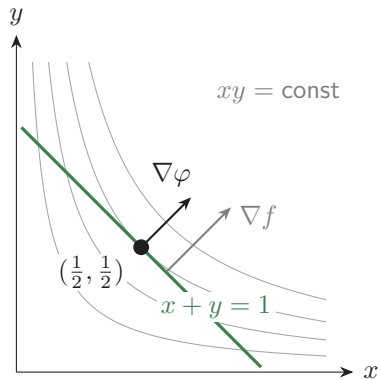
Lagrange liefert nur den *Kandidaten*. Dass das wirklich das Maximum ist, muss man extra zeigen. Hier geht es elementar: Es ist $(x + y)^2 - 4xy = (x - y)^2 \geq 0$, also $xy \leq \frac{1}{4}(x + y)^2 = \frac{1}{4}$.

- In Lean findet die Taktik nlinarith diesen Beweis selbst, mit dem Hinweis $(x - y)^2 \geq 0$.
- Arbeitsteilung: Lagrange verengt die Suche auf endlich viele Punkte, das Optimum bestätigen muss man von Hand.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.6: den Hinweis $(x - y)^2 \geq 0$ weglassen

Wo die Höhenlinie die Straße nur streift

- Eine Straße durchs Gebirge: Die Straße ist die Nebenbedingung $f = \text{const}$, die Höhenlinien sind die Niveaulinien von φ.
- *Kreuzt* die Straße eine Höhenlinie, geht es zur einen Seite bergauf, zur anderen bergab – dort liegt kein Extremum.
- Ein Extremum kann erst liegen, wo sie eine Höhenlinie nur *berührt*: gleiche Tangente, parallele Normalen. Die Normale ist der Gradient, also $\nabla\varphi \parallel \nabla f$.



Lagrange in der Mathlib-Fassung

Satz (Lagrange, Mathlib)

Hat φ unter $f(x) = f(x_0)$ in x_0 ein lokales Extremum und sind f, φ in x_0 streng differenzierbar, so gibt es $(\Lambda, \Lambda_0) \neq (0,0)$ mit $\quad \Lambda \cdot Df(x_0) + \Lambda_0 \cdot D\varphi(x_0) = 0.$

Mathlib formuliert den Satz *projektiv* und kommt damit ohne Regularitätsvoraussetzung aus. Der Zusammenhang mit der klassischen Fassung:

- **Fall** $\Lambda_0 \neq 0$**.** Man darf teilen: $D\varphi(x_0) = -(\Lambda/\Lambda_0)\, Df(x_0)$ – die klassische Form mit $\lambda = -\Lambda/\Lambda_0$.
- **Fall** $\Lambda_0 = 0$**.** Dann ist $\Lambda \neq 0$ und $\Lambda\, Df(x_0) = 0$, also $Df(x_0) = 0$ – genau die Situation, die die klassische Fassung ausschließen muss.
- Ist $Df(x_0) \neq 0$, fällt der zweite Fall weg: Unter denselben Differenzierbarkeitsvoraussetzungen folgt die klassische Fassung aus der projektiven.

Klassisch aus projektiv, in Lean

In Lean ist die klassische Fassung ein Satz, mit genau ihren Voraussetzungen. Der Beweis hat zwei Schritte:

1. Mathlibs projektiver Satz, der Satz der vorigen Folie, liefert $(\Lambda, \Lambda_0) \neq (0, 0)$.
2. Ein eigenes Lemma macht die Fallunterscheidung, reine lineare Algebra: $\Lambda_0 = 0$ führt auf $Df(x_0) = 0$, sonst teilt man durch Λ_0.

Das λ heißt in Lean μ, denn λ ist dort für Funktionen reserviert.

Beispiel (Warum es $Df(x_0) \neq 0$ braucht)

$f(x) = x^2$, $\varphi(x) = x$ auf $\mathbb{R}$, $x_0 = 0$: Die Nebenbedingung $x^2 = 0$ lässt nur $x = 0$ zu, also liegt dort ein Extremum. Aber $D\varphi(0) = 1$ und $Df(0) = 0$ – kein λ mit $1 = \lambda \cdot 0$. Projektiv geht es: $\Lambda = 1$, $\Lambda_0 = 0$.

Live in Lean `code/Vorlesung06.lean` – Abschnitt 4.6: erst das Lemma mit der Fallunterscheidung, dann der Satz

Zusammenfassung

- Taylor in mehreren Veränderlichen: auf der Strecke $g(t) = f(p + th)$ mit Taylor in einer Variablen. Bis zur zweiten Ordnung $f(p + h) = f(p) + \nabla f(p) \cdot h + \frac{1}{2}\, h^{\top} H_f(p)\, h + o(\|h\|^2)$.
- Hoch-, Tief- und Sattelpunkte: Am lokalen Extremum ist $\nabla f = 0$ (Fermat). Ob dort ein Extremum liegt, entscheidet die Hesse-Matrix: positiv definit Tiefpunkt, negativ definit Hochpunkt, indefinit Sattelpunkt. In zwei Dimensionen genügen Determinante und a, in höheren die Vorzeichen der Eigenwerte.
- Gradientenabstieg: $-\nabla f$ ist die Richtung des steilsten Abstiegs. Auf x^2 ist $x_n = (1 - 2t)^n\, x_0$, Konvergenz für $0 < t < 1$; allgemein sinkt f für $0 < t < 2/L$. In zwei Variablen multipliziert ein Schritt den Fehler mit $I - tA$.
- Lagrange in Mathlib: projektiv; klassisch, sobald $Df(x_0) \neq 0$.

Nächstes Mal: Differentialgleichungen I – Existenz und Eindeutigkeit

- Der Schritt zu Differentialgleichungen: Gleichungen für Funktionen, das Anfangswertproblem, das Integral in Mathlib – und aus der Gleichung wird ein Fixpunktproblem.
- Stetigkeit reicht nicht: Gegenbeispiele – und die Lipschitz-Bedingung.
- Vollständigkeit: Cauchy-Folgen, $\mathbb{Q}$ ist nicht vollständig, Banachraum.
- Der Banachsche Fixpunktsatz mit Beweis, und mit ihm Picard–Lindelöf: lokale Existenz und Eindeutigkeit. Dazu Grönwall und der Lösungsraum linearer Systeme.

Lean live: Blatt 6, Teil B

- `lean/Blatt06.lean` in VS Code öffnen und jedes sorry durch einen Beweis ersetzen.
- Lokale Extrema sind Aussagen „schließlich längs $\mathcal{N}(p)$“: Eine große Menge wählen, dann ist es eine Ungleichung an einem Punkt.
- Kein Extremum zeigt man mit einem Punkt in jeder Kugel, an dem f kleiner bzw. größer ist.
- Anfangen mit B1: das lokale Minimum der Funktion aus A1.

Live in Lean `code/Vorlesung06.lean` – zum Nachschlagen: alle Beweise von heute, in der Reihenfolge der Folien